



MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

**KUTUP: YAPAY ZEKÂ DESTEKLİ DEPARTMAN
VE ÇALIŞAN ANALİZ SİSTEMİ**

**AYŞE CANSU YILDIRIM
ŞERİFE SENA ÖZİŞCİ**

LİSANS BİTİRME TEZİ

**DANIŞMAN
DR.ÖĞR. ÜYESİ NAZLI TOKATLI**

İSTANBUL, 2026



MÜHENDİSLİK FAKÜLTESİ

KUTUP: YAPAY ZEKÂ DESTEKLİ DEPARTMAN VE ÇALIŞAN ANALİZ SİSTEMİ

..... tarafından hazırlanan proje çalışması
..../..../..... tarihinde komitemiz tarafından ile İstanbul Sağlık ve
Teknoloji Üniversitesi Mühendislik ve Doğa Bilimleri Fakültesi
..... Bölümünde Lisans BİTİRME PROJESİ olarak kabul
.....

Proje Danışmanı

Dr. Öğr. Üyesi Nazlı TOKATLI
İstanbul Sağlık ve Teknoloji Üniversitesi

Jüri Üyeleri

Dr. Öğr. Üyesi Kemal Çağrı SERDAROĞLU
İstanbul Sağlık ve Teknoloji Üniversitesi

Dr. Öğr. Üyesi İlknur DÖNMEZ
İstanbul Sağlık ve Teknoloji Üniversitesi

Dr. Öğr. Üyesi
İstanbul Sağlık ve Teknoloji Üniversitesi

İÇİNDEKİLER

İÇİNDEKİLER.....	i
SEMBOLLER.....	iii
KISALTMALAR	iv
ŞEKİL LİSTESİ.....	v
ÇİZELGE LİSTESİ.....	vi
ÖZET.....	vii
ABSTRACT	ix
1.GİRİŞ.....	1
1.1 Projenin Amaç ve Kapsamı.....	1
1.2 Proje Konusunun Anlam ve Önemi.....	2
1.3 Problem Tanımı.....	3
1.4 Geliştirilen Çözümün Genel Yapısı	4
2.KURAMSAL TEMELLER VE LİTERATÜR TARAMASI.....	6
2.1 Performans Yönetim Sistemleri.....	6
2.2 İnsan Kaynakları Alanında Makine Öğrenmesi Uygulamaları.....	7
2.3 Toplu Öğrenme Yöntemleri (Ensemble Methods)	9
2.4 Web Tabanlı Yazılım Mimarileri	12
2.5 Rol Tabanlı Erişim Kontrolü ve Güvenlik.....	14
2.6 Doğal Dil İşleme ve Duygu Analizi	16
2.7 Benzer Sistemlerin Karşılaştırması	19
2.7.1 Literatürdeki Boşluk ve KUTUP'un Konumlandırılması.....	20
3.MATERYAL VE YÖNTEM.....	22
3.1 Kullanılan Teknolojiler.....	22
3.1.1 Arka Uç Teknoloji Yığını	22
3.1.2 Ön Yüz Teknoloji Yığını	23
3.1.3 Veritabanı ve Altyapı.....	24
3.2 Sistem Mimarisi.....	25
3.3 Veritabanı Tasarımı.....	27
3.4 Yazılım Departmanı KPI Seti ve Eşik Değerleri	32
3.5 Satış Departmanı KPI Seti ve Eşik Değerleri	36
3.5.1 KPI Eşik Değerlerinin Belirlenmesi	37
3.5.2 Satış Departmanı KPI Kategorileri.....	38
3.6 Makine Öğrenmesi Pipeline'ı	41
3.6.1 Genel İş Akışı.....	41
3.6.2 Özellik Mühendisliği.....	42
3.6.3 Model Seçimi ve Bütünleşik Risk Skoru	44
3.7 Veri Kümesi Hazırlığı	47
3.8 Deneysel Tasarım ve Değerlendirme Metodolojisi.....	49
3.8.1 Eğitim ve Test Verilerinin Ayrılması	49
3.8.2 Değerlendirme Ölçütleri.....	50

3.8.3 Model Seçim Kriterleri	51
3.8.4 DeneySEL Ortam	51
4.BULGULAR	52
4.1 Makine Öğrenmesi Model Performansı	52
4.2 Geliştirilen Sistem Modülleri	53
4.2.1 Rol Tabanlı Giriş ve Yönlendirme	53
4.2.2 Admin Paneli	54
4.2.3 Yönetici Paneli.....	54
4.2.4 Çalışan Paneli	55
4.2.5 LLM Destekli Raporlama	56
4.3 Teknik Bulgular.....	56
4.3.1 Performans Optimizasyonu Sonuçları.....	56
4.3.2 Özellik Mühendisliği ve Değişken Önemi Analizi.....	57
4.3.3 Sistem Mimarisi ve Genişletilebilirlik Bulguları.....	58
4.3.4 Veri Üretimi ve Veri Seti Özeti.....	59
5.SONUÇ VE ÖNERİLER	60
5.1 Projenin Değerlendirilmesi.....	60
5.2 Özgün Değer ve Akademik Katkıları	61
5.3 Sınırlılıklar.....	62
5.4 Gelecek Çalışma Önerileri.....	62
KAYNAKLAR.....	64
EKLER	67
EK A. Sistem Ekran Görüntüleri	67
Ek B — Veritabanı Şeması.....	68
Ek C —Örnek Veri Kümesi	68
EK D — İlk Eğitimlerde Model Çıktıları.....	69
ÖZGEÇMİŞ	70

SEMBOLLER

$\in$	Ait olma / kümeye üyelik operatörü (örn. ARS tahmini $\in [0,1]$)
$\times$	Çarpma operatörü
$+$	Toplama operatörü
$/$	Bölme / oran operatörü
$\geq$	Büyük veya eşit
$\leq$	Küçük veya eşit
$>$	Büyük
$<$	Küçük
$\approx$	Yaklaşık eşit
$\pm$	Artı veya eksi / standart sapma etrafındaki aralık
σ	Standart sapma
TP	True Positive (Gerçek Pozitif)
TN	True Negative (Gerçek Negatif)
FP	False Positive (Yanlış Pozitif)
FN	False Negative (Yanlış Negatif)
%	Yüzde
n	Gözlem / örnek sayısı
$\emptyset$	Çap
Kd	Türev kontrolör katsayısı
t	Zaman (saniye)

KISALTMALAR

KISALTMALAR

ARS	Attrition Risk Score (İşten Ayrılma Riski Skoru)
API	Application Programming Interface (Uygulama Programlama Arayüzü)
BY	Bug Yoğunluğu
CRUD	Create, Read, Update, Delete
ER	Entity-Relationship (Varlık-İlişki)
F1	F1 Skoru (harmonik ortalama: precision ve recall)
GKE	Görelî Katkı Endeksi
GTO	Görev Tamamlama Oranı
HGB	Histogram Gradient Boosting
HR	Human Resources (İnsan Kaynakları)
JWT	JSON Web Token
KKKE	Kod Katkı Kalite Endeksi
KPI	Key Performance Indicator (Temel Performans Göstergesi)
KVKK	Kişisel Verilerin Korunması Kanunu
LLM	Large Language Model (Büyük Dil Modeli)
LR	Logistic Regression (Lojistik Regresyon)
ML	Machine Learning (Makine Öğrenmesi)
MTE	Motivasyon Trend Eğimi
NLP	Natural Language Processing (Doğal Dil İşleme)
ORM	Object-Relational Mapping
RBAC	Role-Based Access Control (Rol Tabanlı Erişim Kontrolü)
REST	Representational State Transfer
RF	Random Forest (Rastgele Orman)
ROC-AUC	Receiver Operating Characteristic — Area Under Curve
SPA	Single Page Application (Tek Sayfa Uygulama)
SQL	Structured Query Language
XAI	Explainable Artificial Intelligence (Açıklanabilir Yapay Zekâ)
XGB	XGBoost
YZ	Yapay Zekâ
ZTO	Zamanında Teslim Oranı

ŞEKİL LİSTESİ

Şekil 1.1 KUTUP Genel Kavramsal Yapısı	4
Şekil 2.1 Performans Yönetiminde Öngörücü Analitik Olgunluk Seviyeleri	6
Şekil 2.2 Veri Sinyallerinin Bütünleşik Risk Skoruna Dönüşümü	8
Şekil 3.1 KUTUP Sistem Mimarisi	24
Şekil 3.2 KUTUP Veri Akış Diyagramı	27
Şekil 3.3 Veritabanı Varlık-İlişki (ER) Diyagramı	28
Şekil 3.4 KUTUP Sisteminde Kullanılan Makine Öğrenmesi Pipeline Mimarisi	41
Şekil 4.1 Toplu Tahmin Optimizasyonu Sonuçları	57
Şekil 4.2 Makine Öğrenmesi Satış Modeli Özellik Önem Sıralaması	58

ÇİZELGE LİSTESİ

Çizelge 1.1	KUTUP Sisteminin Temel Bileşenleri	4
Çizelge 2.1	Performans Yönetim Sistemleri Karşılaştırması	18
Çizelge 3.1	Arka Uç Teknoloji Yığını	22
Çizelge 3.2	Veritabanı Temel Tablo Yapısı	30
Çizelge 3.3	Yazılım Departmanı KPI Seti ve Eşik Değerleri	35
Çizelge 3.4	Satış Departmanı KPI Setinin Tam Tanımları	40
Çizelge 3.5	Eğitimde Kullanılan ML Modelleri ve Hiperparametreleri	45
Çizelge 3.6	Veri Kümesi Özeti	48
Çizelge 4.1	Satış Departmanı ML Model Performansı (Stacking Ensemble)	52
Çizelge 4.2	Yazılım Departmanı ML Model Performansı (Random Forest)	54
Çizelge 4.3	Rol Tabanlı Giriş ve Yönlendirme Matrisi	53

ÖZET

KUTUP: YAPAY ZEKÂ DESTEKLİ DEPARTMAN VE ÇALIŞAN ANALİZ SİSTEMİ

AYŞE CANSU YILDIRIM

ŞERİFE SENA ÖZİŞCİ

Bilgisayar Mühendisliği Bölümü

Bitirme Projesi

Proje Danışmanı: Dr. Nazlı Tokatlı

Bu tez çalışması, Yazılım Geliştirme ve Satış departmanlarında çalışan performansının izlenmesi, değerlendirilmesi ve olası risklerin önceden belirlenmesine yönelik geliştirilen makine öğrenmesi tabanlı performans analiz platformu KUTUP'un tasarımını, geliştirilmesini ve değerlendirilmesini kapsamaktadır. Çalışmanın çıkış noktası geleneksel performans yönetimi yaklaşımlarının büyük ölçüde öznel değerlendirmelere dayanması, performans sorunlarını çoğunlukla ortaya çıktıktan sonra tespit edebilmesi ve yönetsel karar süreçlerinde sınırlı öngörü sunmasıdır.

Bu kapsamda geliştirilen sistem; FastAPI tabanlı arka uç servisi, Vue.js ve TypeScript ile geliştirilen kullanıcı arayüzü ile PostgreSQL tabanlı veri katmanından oluşan çok katmanlı bir mimari üzerine kurulmuştur. Makine öğrenmesi bileşeninde, departmanların operasyonel özelliklerine uygun olarak farklı modelleme yaklaşımları kullanılmış; performans düşüşü, tükenmişlik, istifa riski ve yüksek risk durumlarının öngörülmesine yönelik bağımsız sınıflandırma modelleri geliştirilmiştir.

KUTUP, çalışan performansını değerlendirmek amacıyla temel performans göstergeleri, 360 derece geri bildirimler, haftalık nabız anketleri ve organizasyonel ağ analizi

verilerini bütünsel bir analitik çerçevede bir araya getirmektedir. Ayrıca doğal dil işleme teknikleri kullanılarak geribildirim metinleri analiz edilmekte ve büyük dil modeli destekli raporlama mekanizmaları aracılığıyla yöneticilere açıklanabilir ve yorumlanabilir karar desteği sunulmaktadır. Sistem, rol tabanlı erişim kontrolü ve konteyner tabanlı dağıtım altyapısı ile kurumsal kullanıma uygun şekilde tasarlanmıştır.

Elde edilen bulgular, çok kaynaklı insan kaynakları verilerinin makine öğrenmesi yöntemleriyle bütünlendirilmesinin çalışan performansının daha nesnel biçimde değerlendirilmesine, potansiyel risklerin erken aşamada belirlenmesine ve veri odaklı yönetim süreçlerinin desteklenmesine önemli katkılar sağladığını göstermektedir.

Anahtar Kelimeler: Makine Öğrenmesi, Doğal Dil İşleme, Performans Analizi, Veri Odaklı Yönetim, 360 Derece Geri Bildirim

ABSTRACT

KUTUP: ARTIFICIAL INTELLIGENCE-BASED DEPARTMENT AND EMPLOYEE ANALYSIS SYSTEM

AYŞE CANSU YILDIRIM
ŞERİFE SENA ÖZİŞCİ

Department of Computer Engineering
Graduation Project

Supervisor: Dr. Nazlı Tokatlı

This thesis presents the design, development, and evaluation of KUTUP, a machine learning-based performance analysis platform developed to monitor employee performance, evaluate workforce productivity, and identify potential risks in advance within the Software Development and Sales departments. The motivation behind this study stems from the limitations of traditional performance management approaches, which largely rely on subjective assessments, often detect performance-related issues only after they have emerged, and provide limited predictive insights to support managerial decision-making processes.

The proposed system is built upon a multilayer architecture consisting of a FastAPI-based backend service, a user interface developed using Vue.js and TypeScript, and a PostgreSQL-based data layer. Within the machine learning component, different modeling approaches were employed in accordance with the operational characteristics of each department. Independent classification models were developed to predict performance decline, burnout, turnover risk, and high-risk employee conditions.

To evaluate employee performance, KUTUP integrates key performance indicators, 360-degree feedback, weekly pulse surveys, and organizational network analysis data within a

unified analytical framework. Furthermore, feedback texts are analyzed using natural language processing techniques, while explainable and interpretable decision support is provided to managers through large language model-assisted reporting mechanisms. The system has been designed for enterprise-level use through the implementation of role-based access control and container-based deployment infrastructure.

The findings demonstrate that integrating multi-source human resources data with machine learning techniques contributes significantly to the objective evaluation of employee performance, the early identification of potential risks, and the support of data-driven management processes.

Keywords: Machine Learning, Natural Language Processing, Performance Analysis, Data-Driven Management, 360-Degree Feedback

1.Giriş

1.1 Projenin Amaç ve Kapsamı

Bilgi ekonomisinin hâkim olduğu günümüz kurumsal ortamında organizasyonel başarı büyük ölçüde insan kaynağının etkin, nesnel ve zamanlı biçimde yönetilmesine bağlıdır. Çalışan motivasyonu, üretkenlik eğilimi, ekip içi etkileşim kalitesi ve işten ayrılma niyeti gibi dinamikler; geleneksel yıllık değerlendirme döngüleriyle yeterince yakalanamayan ancak haftalık granüleritede toplanan çok kaynaklı verilerle erken aşamada sinyal veren süreçlerdir. Bu çalışma kapsamında geliştirilen KUTUP platformu; söz konusu dinamikleri periyodik KPI veri akışı, 360 derece geri bildirim mekanizması, nabız anketleri, makine öğrenmesi tabanlı çok hedefli risk tahminlemesi, doğal dil işleme ile duygu/uçuş riski analizi ve RAG mimarisine uyumlu vektör tabanlı altyapısıyla bütünleşik biçimde değerlendiren; yöneticilere Gemini LLM destekli Türkçe raporlarla karar desteği sunan bir analitik platform olarak tasarlanmıştır.

KUTUP'un temel amacı, Yazılım Geliştirme ve Satış departmanlarındaki çalışanların performansını nesnel göstergeler (KPI) aracılığıyla haftalık frekansta ölçmek; Performans Düşüşü, Tükenmişlik, İstifa Riski ve Yüksek Risk olmak üzere dört kritik riski makine öğrenmesi modelleriyle önceden tahmin etmek ve bu ML çıktılarını nabız anketi (işten ayrılma riski skoru) ile 360 derece geri bildirim NLP sinyallerini (uçuş riski) ağırlıklandırarak tek bir bütünleşik risk skoruna dönüştürmektir. Bu skora göre sıralanan en güvenli ve en riskli beşer çalışan otomatik olarak belirlenmekte; en güvenli grup için ödüllendirme önerileri (performans primi, sertifika, kariyer gelişim bütçesi vb.) ile çalışan adına çeşitli yardım kuruluşlarına (LÖSEV, TEMA Vakfı, Türk Kızılay, UNICEF Türkiye gibi) sembolik bağış seçenekleri sunulmakta; en riskli grup için ise ML sinyallerine dayalı, önceliklendirilmiş (Acil/Yüksek/Orta/Düşük) somut müdahale planları (birebir görüşme, yük azaltma, mentorluk vb.) otomatik olarak oluşturulmaktadır. Sistem, bu çok kaynaklı analiz sonuçlarını departman yöneticileri ile üst yönetime anlaşılır, görsel raporlar ve LLM destekli yönetici özetleri aracılığıyla iletmekte; çalışanlara da kendi performans verilerine şeffaf erişim imkânı tanıyarak içsel motivasyonu desteklemektedir.

Performans yönetiminde veri odaklı ve öngörücü yaklaşımların önemi literatürde sıklıkla vurgulanmaktadır. Çalışan motivasyonu ve işten ayrılma eğilimi gibi dinamiklerin erken sinyallerle tespit edilebilmesi, kurumların reaktif değil proaktif İK kararları almasına olanak tanımaktadır. KUTUP, bu yaklaşımı somutlaştırmak üzere haftalık veri toplama

döngüsü, makine öğrenmesi tabanlı risk tahminlemesi ve çok kaynaklı bütünleşik skor mekanizmasını tek bir platformda bir araya getirmektedir.

Kapsam açısından KUTUP aşağıdaki bileşenleri içermektedir:

- Haftalık KPI veri kümesi yükleme ve makine öğrenmesi model eğitimi
- 360 derece geri bildirim modülü, NLP tabanlı duygu/uçuş riski analizi ve performansa dayalı rozet (badge) sistem
- Haftalık nabız anketi ile işten ayrılma riski skoru (ARS) hesaplama
- Organizasyonel ağ analizi: geri bildirim etkileşimlerinden türetilen departmanlar arası bağlantı grafiği, merkezilik (centrality) skoru, silo ve köprü departman tespiti
- Google Gemini LLM entegrasyonu ile Türkçe yönetimsel raporlama
- Rol tabanlı erişim kontrolü (RBAC) ile admin, yönetici ve çalışan arayüzleri
- Docker Compose altyapısıyla üç servisli konteyner tabanlı dağıtım
- Üç veri kaynağının da mevcut olduğu durumlarda ML tahminleri (%60), nabız anketi ARS skoru (%20) ve 360° NLP uçuş riski sinyali (%20) ağırlıklandırılarak hesaplanan; eksik kaynak durumunda kalan ağırlıkların orantılı biçimde yeniden dağıtıldığı bütünleşik risk skoru

1.2 Proje Konusunun Anlam ve Önemi

İnsan Kaynakları Bilişimi (HRIS) alanındaki akademik literatür, çalışan bağlılığı ile örgütsel verimlilik arasında güçlü ve anlamlı bir korelasyon bulunduğunu tutarlı biçimde ortaya koymaktadır. Gallup'un 2023 Küresel Çalışan Bağlılığı Raporu'na göre, aktif olarak işe bağlı çalışanların küresel oranı yalnızca %23 düzeyindeyken; bağlılığı düşük çalışanların yol açtığı verimlilik kayıpları ve işgücü devir hızı maliyetleri, yıllık bazda kurumların toplam maaş giderlerinin %200'üne kadar çıkabilmektedir [15]. Bu gerçeklik, öngörücü analitik yaklaşımların İK yönetimindeki stratejik değerini somut biçimde ortaya koymaktadır.

Geleneksel performans değerlendirme süreçleri, pek çok kurumsal açıdan yetersiz kalmaktadır. Yıllık ya da yarıyıllık döngülerle yürütülen bu sistemler, bir yanda subjektif değerlendirici eğilimlerini (halo etkisi, yakınlık önyargısı) barındırırken öte yanda sorunların kronikleşmesinin ardından devreye girmektedir. Özellikle yazılım geliştirme ve satış gibi dinamik, yüksek baskı altındaki departmanlarda bir çalışanın tükenmişlik sürecine girdiğinin fark edilmesi çoğunlukla istifa kararıyla eş zamanlı gerçekleşmektedir. Oysa davranışsal ve

motivasyonel sinyaller, çok daha erken haftalarda veri tabanlı araçlarla tespit edilebilir niteliktedir.

Bu bağlamda KUTUP projesinin birden fazla düzlemde özgün bir değer sunduğu görülmektedir. Birinci düzlemde, çok kaynaklı veri entegrasyonu gerçekleştirilmektedir: nicel KPI metrikleri, 360 derece geri bildirim kaynaklı duygu sinyalleri ve nabız anketi bulguları bütünleşik bir modelleme çerçevesinde bir araya getirilmektedir. İkinci düzlemde, departmana özgü özellik mühendisliği (feature engineering) ile zaman serisi türevleri (gecikmeli değerler, hareketli ortalamalar, doğrusal eğimler) statik anlık görüntü (snapshot) yaklaşımının ötesine geçmektedir. Üçüncü düzlemde ise Google Gemini LLM entegrasyonu, ham ML çıktılarını yöneticilerin doğrudan kullanabileceği Türkçe bağlamsal raporlara dönüştürmektedir. Böylece sistem yalnızca bir tahmin motoru değil, aynı zamanda eyleme dönük bir karar destek aracına dönüşmektedir.

Yazılım mühendisliği perspektifinden bakıldığında proje, çeşitli teknik katkılar da barındırmaktadır: FastAPI ve Vue.js 3 çerçevelerinin üretim kalitesinde entegrasyonu, scikit-learn Pipeline mimarisi üzerine kurulu modüler ve genişletilebilir bir ML servis katmanı, rol tabanlı erişim kontrolü ile doğrusal olmayan uygulama yetkilendirmesi ve 59 katlık performans optimizasyonu (toplu tahmin: 43.562 ms → 736 ms) bu katkıların somut örnekleri arasında sayılabilir.

Sonuç olarak KUTUP, akademik araştırma ve endüstriyel uygulama arasındaki köprüyü kurmaktadır. Bilgisayar mühendisliği, veri bilimi ve insan kaynakları yönetimi disiplinlerini gerçek bir yazılım ürünüde birleştirerek hem teknik hem de kurumsal açıdan somut değer üreten bir sistem sunmaktadır.

1.3 Problem Tanımı

Pek çok kuruluş, çalışan performans değerlendirmesini yılda bir ya da yarıyılıda bir gerçekleştirilen, büyük ölçüde yönetici sezgisine ve öznel gözlemlere dayanan süreçlerle yürütmektedir. Bu yaklaşımın somut sorunları beş ana başlık altında özetlenebilir:

1. **Gecikmeli Geri bildirim:** Performans sorunları ancak belirgin hale geldiğinde tespit edilmekte, erken müdahale fırsatı kaçırılmaktadır. Bir çalışanın

motivasyon düşüşü, hata artışı ve nihayet istifa kararı genellikle aylarca süren sessiz bir kötüleşme sürecinin sonucudur.

2. **Öznellik ve Değerlendirici Önyargısı:** Halo etkisi, yakınlık önyargısı ve merkezi eğilim gibi bilişsel önyargılar, nesnel metriklerin gölgede kalmasına yol açmaktadır. Farklı yöneticilerin aynı performans seviyesindeki çalışanları farklı puanlaması, kurumsal adaleti zedelemektedir.

3. **Veri Siloları:** KPI verileri, anket sonuçları ve geribildirim formları genellikle farklı sistemlerde, birbirinden izole biçimde tutulmaktadır. Bu parçalı yapı, bütünleşik bir çalışan risk profili oluşturmayı fiilen imkânsız kılmaktadır.

4. **Öngörüsüz Karar Alma:** Mevcut İK sistemlerinin büyük çoğunluğu geçmişe dönük raporlama sunarken, yaklaşan istifa ya da tükenmişlik riskini önceden sinyalleymemektedir. Bu reaktif yaklaşım, stratejik insan kaynağı planlamasını güçleştirmektedir.

5. **Ölçeklenebilirlik Eksikliği:** Elektronik tablo tabanlı takip çözümleri ekip büyüdükçe yönetilemez hale gelmektedir. Veri tutarlılığı, sürüm kontrolü ve çok kullanıcı erişim gibi temel gereksinimler karşılanamamaktadır.

KUTUP, bu beş soruna yanıt vermek üzere haftalık veri toplama döngüsü, ML tabanlı risk tahminlemesi, NLP destekli geribildirim analizi ve çok kaynaklı bütünleşik skor mekanizmasını tek bir platformda bir araya getirmektedir. Sistem, sorunları gerçekleştikten sonra raporlamak yerine olası sorunları gerçekleşmeden önce sinyal vererek öngörücü ve eyleme dönük bir performans analizi platformu oluşturmayı hedeflemektedir.

1.4 Geliştirilen Çözümün Genel Yapısı

KUTUP, katmanlı bir yazılım mimarisine sahiptir ve üç temel katmandan oluşmaktadır:


1. **Sunum Katmanı (Frontend):** Vue.js 3 ve TypeScript ile geliştirilen tek sayfalı uygulama (SPA), üç farklı kullanıcı rolüne (admin, departman yöneticisi, çalışan) özgü dinamik arayüzler sunmaktadır. Tailwind CSS ile stilize edilen arayüz, Chart.js ile veri görselleştirmesini barındırmaktadır.

2. **İş Mantığı Katmanı (Backend):** FastAPI çerçevesiyle geliştirilen RESTful API, 50'den fazla uç noktayı JWT kimlik doğrulama ve RBAC yetkilendirmesiyle güvence altında sunmaktadır. SQLAlchemy ORM aracılığıyla PostgreSQL 15 veritabanıyla iletişim kuran bu katman, makine öğrenmesi servisleri, NLP analiz motorları ve Google Gemini LLM entegrasyonunu yönetmektedir.

3. **Veri ve ML Katmanı:** PostgreSQL 15 + pgvector veritabanı 15'ten fazla ilişkisel tabloyla çalışan, KPI, anket, geribildirim ve ML artifact verilerini depolamaktadır. ML katmanı; bölüme özgü özellik mühendisliği pipeline'ları, scikit-learn uyumlu model eğitim/tahmin servisleri ve joblib tabanlı model artifact deposundan oluşmaktadır.

Bileşen	Teknoloji	Port	Notlar
Frontend	Vue.js 3 + TypeScript + Tailwind CSS	5173	Vite dev sunucu
Backend	FastAPI+SQLAlchemy+Uvicorn	8001	13 router modülü
Veritabanı	PostgreSQL 15 + pgvector	5432	15+ tablo
ML Altyapısı	scikit-learn, LightGBM, XGBoost	Servis içi	Stacking ensemble
NLP / LLM	Google Gemini API	Bulut	İsteğe bağlı
Konteyner	Docker Compose (3 servis)	—	db, backend, frontend

Çizelge 1.1 KUTUP Sisteminin Temel Bileşenleri



Şekil 1.1. KUTUP Genel Kavramsal Yapısı

2.KURAMSAL TEMELLER VE LİTERATÜR TARAMASI

2.1 Performans Yönetim Sistemleri

Performans yönetimi, çalışanların bireysel hedefleri ile organizasyonun stratejik hedeflerini uyumlu hâle getirmeyi amaçlayan sistematik bir yönetim sürecidir. Bu süreç yalnızca performansın ölçülmesini değil; aynı zamanda performansın izlenmesini, değerlendirilmesini, geri bildirim mekanizmalarının işletilmesini ve çalışan gelişiminin desteklenmesini kapsamaktadır. Performans yönetimini hedef belirleme, performansın izlenmesi, geri bildirim sağlanması ve gelişim faaliyetlerinin planlanmasından oluşan bütünlük bir süreç olarak tanımlamaktadır [2].


Geleneksel performans yönetimi uygulamaları çoğunlukla yıllık veya dönemsel değerlendirme döngülerine dayanmaktadır. Ancak bu yaklaşım, çalışan performansındaki değişimlerin gecikmeli olarak fark edilmesine ve değerlendirme süreçlerinde öznel yargıların etkili olmasına neden olabilmektedir. Özellikle dinamik iş ortamlarında faaliyet gösteren organizasyonlarda performansın daha sık izlenmesi ve geri bildirim mekanizmalarının sürekli hâle getirilmesi gerekliliği ortaya çıkmıştır. Bu nedenle son yıllarda sürekli performans yönetimi (Continuous Performance Management) yaklaşımı önem kazanmıştır [6].

Performans yönetiminin etkin biçimde yürütülebilmesi için performansın ölçülebilir göstergeler aracılığıyla izlenmesi gerekmektedir. Rockart tarafından geliştirilen Kritik Başarı Faktörleri yaklaşımı, organizasyonların başarısını etkileyen temel alanların belirlenmesini ve bu alanların düzenli olarak takip edilmesini önermektedir [27]. Kaplan ve Norton tarafından geliştirilen Dengeli Puan Kartı (Balanced Scorecard) yaklaşımı ise performansın yalnızca finansal göstergelerle değil; müşteri, iç süreçler ve öğrenme-gelişim boyutlarıyla birlikte değerlendirilmesi gerektiğini vurgulamaktadır [20]. Günümüzde kullanılan KPI tabanlı performans yönetim sistemleri büyük ölçüde bu kuramsal çerçevelere dayanmaktadır.

Dijital dönüşüm ve veri analitiği teknolojilerinin gelişmesiyle birlikte performans yönetimi sistemleri de önemli bir dönüşüm geçirmiştir. Başlangıçta yalnızca geçmiş performans raporlamaya odaklanan sistemler zamanla performansın nedenlerini analiz eden, gelecekte oluşabilecek durumları tahmin eden ve yöneticilere aksiyon önerileri sunabilen yapılara evrilmiştir. Şekil 2.1'de gösterilen analitik olgunluk modeli bu dönüşümü betimsel

(descriptive), tanımlayıcı (diagnostic), öngörücü (predictive) ve yönlendirici (prescriptive) analitik olmak üzere dört aşamada açıklamaktadır.

Bu çalışmada geliştirilen KUTUP sistemi, performans yönetimini yalnızca geçmiş verilerin raporlanması olarak ele almamakta; haftalık KPI ölçümleri, veri analitiği yöntemleri ve makine öğrenmesi modelleri aracılığıyla performans eğilimlerinin izlenmesini ve potansiyel risklerin önceden belirlenmesini hedeflemektedir. Bu yönüyle sistem, analitik olgunluk modelinde öngörücü ve yönlendirici analitik seviyelerine yaklaşan bir karar destek platformu olarak konumlandırılabilir.



Şekil 2.1. Performans Yönetiminde Öngörücü Analitik Olgunluk Seviyeleri

2.2 İnsan Kaynakları Alanında Makine Öğrenmesi Uygulamaları

Temel Performans Göstergeleri (Key Performance Indicators – KPI), organizasyonların stratejik hedeflere ulaşma düzeylerini ölçmek amacıyla kullanılan nicel performans ölçütleridir. KPI'lar, performansın yalnızca izlenmesini değil aynı zamanda değerlendirilmesini ve yönetilmesini mümkün kılan temel araçlar arasında yer almaktadır. Kurumlar tarafından belirlenen hedeflerin çalışan, ekip veya departman düzeyinde ne ölçüde gerçekleştirildiğinin belirlenmesinde KPI'lar önemli bir rol oynamaktadır. Bu nedenle performans yönetim sistemlerinin etkinliği büyük ölçüde kullanılan performans göstergelerinin doğruluğuna ve anlamlılığına bağlıdır.

Bir KPI'nın etkili olabilmesi için SMART kriterlerini karşılaması gerekmektedir. Doran (1981) tarafından ortaya konulan bu yaklaşım; göstergelerin özgül (Specific), ölçülebilir (Measurable), ulaşılabilir (Achievable), ilgili (Relevant) ve zamana bağlı (Time-bound) olması

gerektiğini ifade etmektedir. SMART yaklaşımı, performans göstergelerinin belirsiz ve yoruma açık ölçütler yerine nesnel ve takip edilebilir metrikler olarak tanımlanmasını sağlamaktadır.

Performans göstergelerinin belirlenmesi kadar bu göstergelerin nasıl yorumlanacağı da önem taşımaktadır. Aynı performans değeri farklı sektörlerde, departmanlarda veya organizasyonlarda farklı anlamlar taşıyabilmektedir. Bu nedenle performans yönetimi uygulamalarında KPI'lar çoğunlukla belirli referans aralıkları ve eşik değerlerle birlikte kullanılmaktadır. Eşik değerler, performans seviyelerinin başarılı, kabul edilebilir veya riskli olarak sınıflandırılmasına olanak sağlayarak yöneticilerin performans durumunu daha hızlı ve tutarlı biçimde değerlendirmesine yardımcı olmaktadır.

Literatürde KPI eşiklerinin belirlenmesinde farklı yöntemler kullanılmaktadır. Bunlar arasında istatistiksel dağılımlara dayalı yaklaşımlar, uzman görüşlerine dayalı değerlendirmeler ve alan yazınında raporlanan ampirik performans aralıkları öne çıkmaktadır. İstatistiksel yaklaşımlar mevcut veri dağılımını temel alırken, uzman görüşüne dayalı yöntemler sektör deneyimini ve operasyonel gereksinimleri dikkate almaktadır. Ampirik yaklaşımlar ise önceki araştırmalarda raporlanan performans seviyelerinden yararlanmaktadır. Güncel performans analitiği çalışmalarında bu yöntemlerin birlikte kullanılması önerilmektedir.


Yazılım geliştirme ve satış gibi farklı iş alanlarında performansı etkileyen faktörler önemli ölçüde değişebilmektedir. Bu nedenle tüm departmanların aynı performans göstergeleriyle değerlendirilmesi çoğu zaman sağlıklı sonuçlar vermemektedir. Yazılım ekiplerinde görev tamamlama oranı, hata yoğunluğu ve iş yükü göstergeleri ön plana çıkarken; satış ekiplerinde hedef gerçekleştirme oranı, müşteri dönüşüm oranı ve teklif başarı oranı gibi metrikler daha anlamlı performans göstergeleri olarak kabul edilmektedir. Bu durum departmana özgü KPI tasarımının önemini ortaya koymaktadır.

Bu çalışma kapsamında geliştirilen KUTUP sisteminde KPI'lar ve eşik değerleri belirlenirken literatürde önerilen yaklaşımlar birlikte değerlendirilmiştir. Eşik değerlerin oluşturulmasında veri dağılımlarına dayalı istatistiksel analizlerden ilgili akademik çalışmalarda raporlanan bulgulardan ve departmanların operasyonel gereksinimlerinden yararlanılmıştır. Böylece performans göstergelerinin yalnızca belirli bir veri kümesine veya kurumsal yapıya bağımlı kalmasının önüne geçilmesi amaçlanmıştır.

Yazılım departmanı için kullanılan performans göstergeleri çevik yazılım geliştirme ve yazılım ölçümleme literatürüne dayandırılmıştır. Görev Tamamlama Oranı (GTO) ve zaman yönetimine ilişkin göstergeler çevik proje yönetimi çalışmalarından [10]; [28], hata yoğunluğu ve kalite metrikleri ise yazılım ölçümleme literatüründen [13]; [17] yararlanılarak oluşturulmuştur. İş yükü göstergelerinin belirlenmesinde ise çalışma saatleri ve tükenmişlik üzerine gerçekleştirilen araştırmalar dikkate alınmıştır [7].

Satış departmanı için kullanılan KPI'lar ise satış performansı ve müşteri ilişkileri yönetimi alanındaki çalışmalara dayanmaktadır. Satış hedeflerinin gerçekleştirilme düzeyi, müşteri dönüşüm oranları ve teklif başarı göstergeleri gibi metrikler satış ekiplerinin performansını değerlendirmede yaygın olarak kullanılan ölçütler arasında yer almaktadır [16] ; [31].

Sonuç olarak KPI'lar ve bunlara ait eşik değerler, performans yönetim sistemlerinin temel ölçüm altyapısını oluşturmaktadır. Bilimsel literatür ve operasyonel gereksinimler dikkate alınarak belirlenen performans göstergeleri, çalışan ve ekip performansının daha nesnel biçimde değerlendirilmesine katkı sağlamak ve veri odaklı karar verme süreçlerini desteklemektedir.



Şekil 2.2. Veri Sinyallerinin Bütünleşik Risk Skoruna Dönüşümü

2.3 Toplu Öğrenme Yöntemleri (Ensemble Methods)

Makine öğrenmesi tekniklerinin kurumsal süreçlerde yaygınlaşmasıyla birlikte çalışan performansının değerlendirilmesi, organizasyonel risklerin belirlenmesi ve karar destek mekanizmalarının geliştirilmesine yönelik çalışmalar önemli ölçüde artmıştır. Geleneksel

performans deęerlendirme yöntemleri çoęunlukla gemiř performansın ölçölmesine odaklanırken makine öğrenmesi yaklaşımları gemiř verilerden öğrenerek gelecekte ortaya çıkabilecek durumların tahmin edilmesine olanak sağlamaktadır. Bu nedenle son yıllarda performans yönetimi, çalışan analitięi ve organizasyonel davranıř arařtırmalarında veri odaklı yöntemlerin kullanımı giderek yaygınlařmıřtır.

Makine öğrenmesinin kurumsal uygulamalardaki temel amacı, büyük miktardaki veriler içerisindeki örüntüleri ortaya çıkararak yöneticilere daha doęru ve zamanında karar desteęi sunmaktır. Marler ve Boudreau, veri analitięi ve makine öğrenmesi tekniklerinin çalışanlara iliřkin karar süreçlerinde giderek daha kritik bir rol üstlendięini belirtmektedir [24]. Benzer řekilde Levenson, organizasyonların yalnızca performans ölçümüne deęil, performansı etkileyen faktörlerin analizine ve geleceęe yönelik öęörülerin oluřturulmasına yöneldięini ifade etmektedir [23].

İřten ayrılma tahmini (employee attrition prediction), makine öğrenmesinin insan kaynakları alanındaki en yaygın uygulamalarından biri olarak kabul edilmektedir. Bu problemde çalışanların demografik özellikleri, performans göstergeleri, iř yükü verileri ve organizasyonel davranıřlarına iliřkin deęiřkenler kullanılarak gelecekte kurumdan ayrılıp ayrılmayacakları tahmin edilmektedir. IBM Watson HR Analytics veri kümesi üzerinde gerekleřtirilen alıřmalar; Random Forest, Gradient Boosting ve benzeri toplu öğrenme yöntemlerinin çalışan ayrılma tahmininde yüksek performans gösterebildięini ortaya koymuřtur [12]. Bu alıřmalar, organizasyonların yalnızca mevcut çalışan durumunu deęerlendirmesinin deęil, potansiyel riskleri önceden belirlemesinin de mümkün olduęunu göstermektedir.

Makine öğrenmesi tabanlı analizlerde yaygın olarak incelenen bir dięer konu çalışan tükenmiřlięi (burnout) riskidir. Tükenmiřlik; uzun süreli iř yükü, stres ve motivasyon kaybının sonucu olarak ortaya ıkan çok boyutlu bir sendrom olarak tanımlanmaktadır. Maslach, tükenmiřlięi duygusal tükenme, duyarsızlařma ve kiřisel başarı hissinde azalma olmak üzere üç temel boyutta ele almaktadır [25]. Bu nedenle alıřma saatleri, iř yükü göstergeleri, performans eęilimleri ve çalışan geri bildirimleri günümüzde tükenmiřlik riskinin belirlenmesinde yaygın olarak kullanılan veri kaynakları arasında yer almaktadır.

Çalışan performansının değerlendirilmesine yönelik araştırmalar yalnızca mevcut performans göstergelerinin kullanılmasının yeterli olmadığını ortaya koymaktadır. Son yıllarda araştırmacılar, performansın zaman içerisindeki değişimini temsil eden dinamik özelliklerin modellere dahil edilmesi gerektiğini vurgulamaktadır. Çünkü çalışan davranışları ve performans göstergeleri statik değil, zamana bağlı olarak değişen yapılar sergilemektedir. Bu nedenle performans eğilimlerinin incelenmesi, yalnızca mevcut durumun değerlendirilmesine kıyasla daha güçlü öngörüler sağlayabilmektedir.

Zaman serisi tabanlı performans modelleme çalışmaları son yıllarda önemli ölçüde artmıştır. Cheng ve Guestrin'in., haftalık üretkenlik verileri üzerinde gerçekleştirdikleri çalışmada eğim (trend) özelliklerinin yalnızca anlık performans değerlerini kullanan modellere kıyasla daha başarılı sınıflandırma sonuçları üretebildiğini göstermiştir [9]. Bu bulgu, çalışan performansının yalnızca mevcut seviyesinin değil, zaman içerisindeki değişim yönünün de değerlendirilmesi gerektiğini ortaya koymaktadır.

Bu doğrultuda modern performans analitiği sistemlerinde gecikmeli değişkenler (lag features), hareketli ortalamalar (rolling averages) ve trend göstergeleri yaygın olarak kullanılmaktadır. Bu özellikler çalışan davranışlarındaki değişimlerin daha doğru temsil edilmesine, performans düşüşlerinin daha erken tespit edilmesine ve organizasyonel risklerin oluşmadan önce belirlenmesine katkı sağlamaktadır.

Bu çalışma kapsamında geliştirilen KUTUP sistemi de literatürde önerilen bu yaklaşımlardan yararlanmaktadır. Sistemde kullanılan makine öğrenmesi modelleri yalnızca anlık KPI değerlerini değil, bu göstergelerin zaman içerisindeki değişimlerini de dikkate almaktadır. Bu amaçla her KPI için gecikme (lag_1), hareketli ortalama (rolling_4) ve doğrusal eğim (trend_4) özellikleri türetilmiş ve performans düşüşü, tükenmişlik riski, işten ayrılma riski ve yüksek risk durumlarının daha doğru tahmin edilmesi hedeflenmiştir.

Sonuç olarak makine öğrenmesi yöntemleri, çalışan performansının ve organizasyonel risklerin değerlendirilmesinde giderek daha önemli bir rol üstlenmektedir. Özellikle zaman serisi tabanlı özellik mühendisliği, toplu öğrenme yöntemleri ve risk tahmin modelleri, performans yönetim sistemlerinin yalnızca geçmişi raporlayan araçlar olmaktan çıkarak geleceğe yönelik karar desteği sunabilen analitik platformlara dönüşmesine katkı sağlamaktadır. KUTUP sistemi de bu yaklaşımı benimseyerek performans göstergeleri,

davranışsal veriler ve zaman serisi özelliklerini birlikte değerlendirerek yöneticilere daha proaktif ve veri odaklı karar desteği sunmayı amaçlamaktadır.

2.4 Web Tabanlı Yazılım Mimarileri

Toplu öğrenme (Ensemble Learning), birden fazla makine öğrenmesi modelinin çıktılarının birleştirilerek daha güçlü ve daha kararlı tahminler üretilmesini amaçlayan bir öğrenme yaklaşımıdır. Bu yöntemlerin temel amacı, tek bir modelin sahip olduğu hata kaynaklarını azaltmak ve genelleme performansını artırmaktır. Ensemble yöntemlerinin arkasındaki temel varsayım, farklı modellerin farklı hata yapıları sergilemesi ve bu hataların uygun şekilde birleştirildiğinde birbirlerini telafi edebilmesidir [4].

Makine öğrenmesi literatüründe ensemble yöntemleri genel olarak bagging, boosting ve stacking olmak üzere üç temel kategori altında incelenmektedir. Bu yöntemlerin ortak amacı, birden fazla öğrenciden elde edilen bilgiyi bir araya getirerek daha güvenilir tahminler oluşturmaktır. Özellikle karmaşık veri yapılarında ve doğrusal olmayan ilişkilerin bulunduğu problemlerde ensemble yöntemlerinin tekil modellere kıyasla daha başarılı sonuçlar üretebildiği birçok çalışmada gösterilmiştir.

Bagging (Bootstrap Aggregating) yaklaşımında aynı algoritmanın farklı veri örnekleri üzerinde eğitilmiş çok sayıda versiyonu oluşturulmakta ve elde edilen tahminler birleştirilmektedir. Bu yaklaşımın en yaygın örneklerinden biri Random Forest algoritmasıdır. Random Forest, çok sayıda karar ağacının çıktılarının birleştirilmesiyle çalışmakta ve tek bir karar ağacına kıyasla daha düşük varyans ve daha yüksek genelleme başarısı sağlamaktadır [4].

Boosting yöntemlerinde ise modeller ardışık olarak eğilmekte ve her yeni model önceki modellerin yaptığı hataları azaltmaya odaklanmaktadır. Bu yaklaşımın günümüzde en yaygın kullanılan örnekleri arasında XGBoost ve LightGBM algoritmaları yer almaktadır. XGBoost, düzenleştirme (regularization) mekanizmaları sayesinde aşırı öğrenme (overfitting) riskini azaltırken yüksek tahmin doğruluğu sağlayabilmektedir [8]. LightGBM ise histogram tabanlı öğrenme yapısı ve yaprak bazlı büyüme stratejisi sayesinde büyük veri kümelerinde daha hızlı eğitim süresi ve daha yüksek hesaplama verimliliği sunmaktadır [21]

Stacking (Stacked Generalization) yaklaşımı ise farklı türdeki modellerin çıktılarının ikinci bir model tarafından öğrenilmesine dayanmaktadır. Bu yöntemde birinci seviyede yer

alan temel öğreniciler (base learners) bağımsız olarak eğitilmekte, ikinci seviyede yer alan meta öğrenici (meta learner) ise bu modellerin tahminlerini kullanarak nihai kararı vermektedir. Wolpert, stacking yönteminin farklı modellerin güçlü yönlerini bir araya getirerek daha yüksek genelleme başarısı sağlayabildiğini göstermiştir [30].

Performans analitiği ve risk tahmini gibi problemlerde kullanılan veri kümeleri çoğu zaman farklı türde değişkenler içermektedir. Performans göstergeleri, davranışsal veriler, zaman serisi özellikleri ve geri bildirimlerden elde edilen bilgiler arasındaki ilişkiler çoğunlukla doğrusal değildir. Bu nedenle tek bir algoritmanın tüm veri yapısını eksiksiz biçimde temsil etmesi her zaman mümkün olmayabilmektedir. Ensemble yöntemleri, farklı öğrenme yaklaşımlarının avantajlarını bir araya getirerek bu sorunun azaltılmasına katkı sağlamaktadır.

Bu çalışma kapsamında geliştirilen KUTUP sisteminde satış departmanına ait risk tahmin modellerinde stacking tabanlı bir ensemble mimarisi tercih edilmiştir. Bu yapıda birinci seviyede LightGBM, XGBoost ve Random Forest algoritmaları paralel olarak eğitilmektedir. Her modelin oluşturduğu tahminler doğrudan kullanılmamakta; bunun yerine çapraz doğrulama sürecinde elde edilen dışarıda bırakılmış (out-of-fold) tahminler ikinci seviyeye aktarılmaktadır. Böylece veri sızıntısı (data leakage) riski azaltılmakta ve modelin gerçek genelleme performansı daha doğru biçimde temsil edilmektedir.

İkinci seviyede ise meta öğrenici olarak Lojistik Regresyon kullanılmaktadır. Bu yaklaşım sayesinde LightGBM'nin karmaşık örüntüleri yakalama yeteneği, XGBoost'un güçlü optimizasyon kapasitesi ve Random Forest'ın kararlı yapısı tek bir model altında birleştirilebilmektedir. Böylece farklı algoritmaların tamamlayıcı özelliklerinden yararlanılarak daha güvenilir risk tahminleri elde edilmesi amaçlanmaktadır.

Sonuç olarak toplu öğrenme yöntemleri, makine öğrenmesi modellerinin doğruluğunu ve genelleme kapasitesini artırmak amacıyla yaygın olarak kullanılan güçlü yaklaşımlar arasında yer almaktadır. Özellikle performans analitiği ve öngörücü risk modelleme çalışmalarında farklı algoritmaların birlikte kullanılması, tek bir modele kıyasla daha kararlı ve daha güvenilir sonuçlar üretilmesine katkı sağlamaktadır. KUTUP sisteminde kullanılan stacking mimarisi de bu yaklaşım doğrultusunda tasarlanmış olup farklı öğrenicilerin güçlü yönlerini bir araya getirerek karar destek mekanizmasının doğruluğunu artırmayı hedeflemektedir.

2.5 Rol Tabanlı Eriřim Kontrolü ve Güvenlik

Modern kurumsal yazılım sistemleri, yüksek erişilebilirlik, ölçeklenebilirlik ve sürdürülebilirlik gereksinimleri nedeniyle çoğunlukla web tabanlı mimariler üzerine inşa edilmektedir. Bu sistemlerde kullanıcı arayüzü, iş mantığı ve veri yönetimi katmanlarının birbirinden ayrılması uygulamanın bakımını, geliştirilmesini ve farklı kullanıcı gruplarına hizmet verebilmesini kolaylaştırmaktadır. Özellikle veri yoğun kurumsal uygulamalarda mimari tasarım kararları, sistem performansı ve güvenliği üzerinde doğrudan etkili olmaktadır.

Günümüzde web tabanlı uygulamalarda yaygın olarak kullanılan mimari yaklaşımlardan biri REST (Representational State Transfer) mimarisidir. Fielding tarafından tanımlanan REST yaklaşımı; istemci-sunucu ayrımı, durumsuz iletişim, önbellekleme desteği ve kaynak tabanlı adresleme prensiplerine dayanmaktadır [14]. REST mimarisinde sistem bileşenleri HTTP protokolü üzerinden haberleşmekte ve her kaynak benzersiz bir URI ile temsil edilmektedir. Bu yapı, farklı istemci uygulamalarının aynı servisleri kullanabilmesine olanak sağlamakta ve yatay ölçeklendirmeyi kolaylaştırmaktadır.

REST mimarisinin önemli avantajlarından biri, istemci ve sunucu taraflarının birbirinden bağımsız olarak geliştirilebilmesidir. Böylece kullanıcı arayüzünde gerçekleştirilen değişiklikler iş mantığını doğrudan etkilememekte, benzer şekilde sunucu tarafında yapılan geliřtirmeler de istemci uygulamasının yeniden tasarlanmasını gerektirmemektedir. Bu yaklaşım özellikle büyük ölçekli yazılım projelerinde sürdürülebilirlik ve bakım kolaylığı sağlamaktadır.

Ön yüz geliştirme tarafında son yıllarda Tek Sayfalı Uygulama (Single Page Application – SPA) mimarisi yaygın olarak kullanılmaktadır. SPA yaklaşımında uygulamanın temel bileşenleri ilk yükleme sırasında istemciye aktarılmakta, sonraki işlemler ise sunucuya yapılan asenkron istekler aracılığıyla gerçekleştirilmektedir. Böylece her kullanıcı etkileşiminde sayfanın tamamen yeniden yüklenmesine gerek kalmamakta ve daha hızlı bir kullanıcı deneyimi sağlanmaktadır. Vue.js, React ve Angular gibi modern ön yüz teknolojileri SPA mimarisinin yaygınlaşmasında önemli rol oynamıştır.

Kurumsal uygulamalarda güvenlik, sistem mimarisinin temel bileşenlerinden biridir. Kullanıcıların sisteme güvenli erişiminin sağlanması, yetkisiz erişimlerin engellenmesi ve hassas verilerin korunması için kimlik doğrulama (authentication) ve yetkilendirme

(authorization) mekanizmaları kullanılmaktadır. Kimlik doğrulama, kullanıcının gerçekten iddia ettiği kişi olup olmadığının belirlenmesini amaçlarken yetkilendirme, doğrulanmış kullanıcının hangi sistem kaynaklarına erişebileceğini tanımlamaktadır.

Yetkilendirme mekanizmaları arasında en yaygın kullanılan yaklaşımlardan biri Rol Tabanlı Erişim Kontrolü (Role-Based Access Control – RBAC) modelidir. Sandhu vd tarafından geliştirilen RBAC modeli, kullanıcıların belirli rollere atanmasını ve erişim izinlerinin bu roller üzerinden yönetilmesini öngörmektedir [29]. Bu yaklaşım, kullanıcı bazlı izin yönetimine kıyasla daha ölçeklenebilir ve daha kolay yönetilebilir bir yapı sunmaktadır. Ayrıca NIST tarafından standartlaştırılmış olması nedeniyle kurumsal sistemlerde yaygın olarak tercih edilmektedir.

Web uygulamalarında oturum yönetimi için kullanılan modern yöntemlerden biri JSON Web Token (JWT) tabanlı kimlik doğrulamadır. JWT, kullanıcıya ait kimlik ve yetki bilgilerinin dijital olarak imzalanmış bir belge şeklinde taşınmasını sağlamaktadır [18]. Bu yaklaşım, sunucu tarafında oturum bilgisinin tutulmasını gerektirmediğinden REST mimarisinin durumsuz yapısıyla uyumlu çalışmaktadır. Ayrıca dağıtık sistemlerde ve mikroservis tabanlı yapılarda performans avantajı sağlayabilmektedir.

Güvenli web uygulamalarının geliştirilmesinde yalnızca kimlik doğrulama ve yetkilendirme mekanizmaları yeterli değildir. Veri aktarımında HTTPS kullanılması, parola bilgilerinin güvenli biçimde saklanması, giriş doğrulama kontrollerinin uygulanması ve erişim kayıtlarının izlenmesi gibi uygulamalar da modern yazılım güvenliğinin önemli bileşenleri arasında yer almaktadır. Bu nedenle güvenlik günümüzde yazılım geliştirme yaşam döngüsünün ayrılmaz bir parçası olarak değerlendirilmektedir.

Bu çalışma kapsamında geliştirilen KUTUP sistemi, modern web mimarileri ve güvenlik prensipleri dikkate alınarak tasarlanmıştır. Sistemin ön yüz katmanında Vue.js tabanlı SPA mimarisi kullanılmış, arka uç tarafında ise REST prensiplerine uygun servis yapısı tercih edilmiştir. Güvenlik katmanında JWT tabanlı kimlik doğrulama ve RBAC tabanlı yetkilendirme mekanizmaları birlikte kullanılarak kullanıcıların yalnızca görev ve sorumlulukları kapsamında yetkilendirilen verilere erişebilmesi sağlanmıştır. Böylece sistemin hem ölçeklenebilir hem de güvenli bir kurumsal performans analitiği ve karar destek platformu olarak çalışması hedeflenmiştir.

2.6 Doğal Dil İşleme ve Duygu Analizi

Kurumsal bilgi sistemlerinde kullanılan verilerin tamamı yapılandırılmış tablolardan oluşmamaktadır. Performans değerlendirme formları, 360 derece geribildirimler, yönetici yorumları, çalışan anketleri ve açık uçlu değerlendirme metinleri gibi birçok veri kaynağı doğal dil biçiminde üretilmektedir. Bu nedenle son yıllarda yapılandırılmamış metin verilerinin analiz edilmesi, kurumsal analitik ve karar destek sistemlerinin önemli araştırma alanlarından biri hâline gelmiştir. Doğal Dil İşleme (Natural Language Processing – NLP), insan dilinin bilgisayarlar tarafından işlenmesini, yorumlanmasını ve anlamlandırılmasını amaçlayan yapay zekâ alt alanı olarak bu ihtiyaca çözüm sunmaktadır [19].

Doğal dil işleme teknikleri günümüzde metin sınıflandırma, duygu analizi, konu modelleme, bilgi çıkarımı ve metin özetleme gibi birçok uygulamada kullanılmaktadır. Kurumsal performans yönetimi bağlamında ise çalışan geri bildirimlerinin değerlendirilmesi, organizasyonel eğilimlerin belirlenmesi ve davranışsal göstergelerin analiz edilmesi amacıyla NLP yöntemlerinden yararlanılmaktadır. Yapılandırılmamış metin verilerinin analiz edilmesi, yalnızca sayısal performans göstergelerine dayalı değerlendirmelerin ötesine geçilmesini sağlayarak daha kapsamlı karar desteği sunabilmektedir.

Duygu analizi (sentiment analysis), NLP alanındaki en yaygın uygulamalardan biridir. Bu yaklaşım, metinlerde yer alan olumlu, olumsuz veya nötr ifadelerin belirlenmesini amaçlamaktadır. Kurumsal ortamlarda duygu analizi; çalışan memnuniyeti, motivasyon düzeyi ve organizasyona yönelik tutumların değerlendirilmesinde kullanılabilir. Özellikle geri bildirim metinlerinde gözlenen olumsuz duygu eğilimlerinin performans düşüşü, motivasyon kaybı ve işten ayrılma davranışı ile ilişkili olabileceği birçok çalışmada raporlanmıştır [26].

Metin madenciliği (text mining) alanındaki gelişmeler, çalışan geri bildirimleri ve organizasyonel iletişim verilerinin analiz edilmesine yönelik ilgiyi artırmıştır. Ancak literatürde yapılandırılmış performans verileri ile metin tabanlı geri bildirimlerin aynı karar destek sistemi içerisinde birlikte kullanıldığı çalışmaların sayısı hâlen sınırlıdır. Bu durum özellikle performans göstergeleri ile davranışsal verilerin bütünlük biçimde değerlendirilmesi açısından önemli bir araştırma alanı oluşturmaktadır.

Doğal Dil İşleme alanındaki en önemli gelişmelerden biri Büyük Dil Modellerinin (Large Language Models – LLM) ortaya çıkmasıdır. Büyük dil modelleri, çok büyük metin koleksiyonları üzerinde eğitilen ve doğal dil üretimi, özetleme, içerik yorumlama ve soru-cevaplama gibi görevleri yüksek başarıyla gerçekleştirebilen yapay zekâ sistemleridir. Brown vd. tarafından tanıtılan GPT-3 modeli, büyük ölçekli dil modellerinin karmaşık dil görevlerinde etkili sonuçlar üretebildiğini göstermiş ve bu alandaki araştırmaların hız kazanmasına katkı sağlamıştır [5].

Günümüzde GPT, Gemini, Claude ve benzeri büyük dil modelleri yalnızca içerik üretiminde değil, aynı zamanda kurumsal analitik ve karar destek sistemlerinde de kullanılmaktadır. Bu modeller sayısal analiz sonuçlarını doğal dilde açıklayabilmekte, teknik çıktıları yorumlayabilmekte ve yöneticilere daha anlaşılır raporlar sunabilmektedir. Böylece veri analitiği sonuçlarının uzman olmayan kullanıcılar tarafından da yorumlanabilmesi kolaylaşmaktadır.

Bu çalışma kapsamında geliştirilen KUTUP sistemi, doğal dil işleme tekniklerini iki farklı seviyede kullanmaktadır. İlk seviyede 360 derece geribildirim metinleri üzerinde duygu analizi gerçekleştirilmekte ve çalışan davranışlarına ilişkin ek göstergeler elde edilmektedir. Bu göstergeler performans verileri ve diğer risk faktörleri ile birlikte değerlendirilerek analiz sürecine dâhil edilmektedir. İkinci seviyede ise Google Gemini API entegrasyonu aracılığıyla makine öğrenmesi modellerinden elde edilen sonuçlar doğal dilde yönetim raporlarına dönüştürülmektedir. Böylece yöneticiler yalnızca sayısal risk skorlarını değil, bu skorların açıklamalarını ve önerilen aksiyonları da inceleyebilmektedir.

KUTUP sisteminde doğal dil işleme analizlerinin temel veri kaynaklarını 360 derece geribildirimler ve haftalık nabız anketleri oluşturmaktadır. Bu veri toplama mekanizmaları, çalışan performansının yalnızca nicel göstergeler üzerinden değil, aynı zamanda çalışan deneyimi ve davranışsal eğilimler üzerinden de değerlendirilmesine olanak sağlamaktadır.

360 derece geribildirim sürecinde çalışanlar; iletişim, takım çalışması, problem çözme, liderlik ve teknik yetkinlik boyutlarında birbirlerini değerlendirmektedir. Sayısal değerlendirmelere ek olarak çalışanların güçlü yönleri ve gelişime açık alanlarına ilişkin açık uçlu görüşleri de sistem tarafından toplanmaktadır. Elde edilen metinsel veriler doğal dil işleme yöntemleri kullanılarak analiz edilmekte; duygu eğilimleri, motivasyon göstergeleri ve olası

organizasyonel risk sinyalleri gibi ek analitik çıktılar üretilmektedir. Böylece performans değerlendirme süreci yalnızca sayısal puanlarla sınırlı kalmayıp çalışan davranışlarının ve ekip içi etkileşimlerin de değerlendirilmesine imkân vermektedir.

Sistemde kullanılan ikinci metin tabanlı veri kaynağı haftalık nabız anketleridir. Bu anketler çalışanların motivasyon düzeyi, iş yükü algısı ve ekip içi destek deneyimi gibi temel çalışma yaşamı göstergelerini düzenli olarak ölçmeyi amaçlamaktadır. Bunun yanında çalışanların haftalık deneyimlerini, karşılaştıkları zorlukları, elde ettikleri başarıları ve iyileştirme önerilerini ifade edebilecekleri açık uçlu sorular da anket kapsamında yer almaktadır. Açık uçlu yanıtlar doğal dil işleme modelleri tarafından analiz edilerek çalışan bağlılığı, motivasyon eğilimleri ve işten ayrılma riskiyle ilişkili davranışsal göstergelerin belirlenmesinde kullanılmaktadır.

Bu iki veri kaynağından elde edilen yapılandırılmamış metin verileri, performans göstergeleri ve diğer analitik bileşenlerle birlikte değerlendirilerek çalışanlara ilişkin daha kapsamlı ve açıklanabilir içgörüler üretilmesine katkı sağlamaktadır. Böylece KUTUP, performans yönetimi süreçlerinde nicel ve nitel verileri bütünleşik biçimde kullanarak daha güçlü bir karar destek mekanizması sunmaktadır.

Kurumsal sistemlerde dış servis bağımlılığının oluşturabileceği erişilebilirlik risklerini azaltmak amacıyla KUTUP'ta çok katmanlı bir raporlama yaklaşımı benimsenmiştir. Büyük dil modeli servisinin geçici olarak kullanılmadığı durumlarda sistem, önceden tanımlanmış kural tabanlı şablonlar aracılığıyla rapor üretmeye devam etmektedir. Bu yaklaşım sistem sürekliliğinin korunmasına ve raporlama hizmetinin kesintisiz şekilde sürdürülebilmesine katkı sağlamaktadır.

Sonuç olarak doğal dil işleme ve büyük dil modelleri, yapılandırılmış performans verileri ile yapılandırılmamış metin verilerinin birlikte değerlendirilmesine olanak sağlamaktadır. KUTUP sistemi de performans göstergeleri, çalışan geri bildirimleri ve büyük dil modeli destekli raporlama mekanizmalarını bir araya getirerek daha kapsamlı ve yorumlanabilir bir karar destek yaklaşımı sunmayı amaçlamaktadır.

2.7 Benzer Sistemlerin Karşılaştırması

Özellik	KUTUP	SAP SuccessFactors	BambooHR	Lattice
ML tabanlı risk tahmini	Evet (4 hedef)	Kısmi	Hayır	Kısmi
Stacking ensemble	Evet	Hayır	Hayır	Hayır
KPI özelleştirme	45 KPI	Evet	Sınırlı	Evet
360° geribildirim + NLP	Evet	Evet	Kısmi	Evet
LLM entegrasyonu	Gemini	Joule (GPT)	Hayır	Hayır
Açık kaynak/özelleştirme	Evet	Hayır	Hayır	Hayır
Konteyner dağıtımı	Docker Compose	SaaS	SaaS	SaaS
Lisans maliyeti	Ücretsiz	Yüksek	Orta	Orta

Çizelge 2.1 Performans Yönetim Sistemleri Karşılaştırması

Çizelge 2.1 incelendiğinde KUTUP'un özellikle makine öğrenmesi tabanlı risk tahmini, stacking ensemble mimarisi ve doğal dil işleme entegrasyonu açısından mevcut ticari çözümlerden ayrıştığı görülmektedir. Sistemde performans düşüşü, tükenmişlik riski, işten ayrılma riski ve yüksek risk durumu olmak üzere dört farklı hedef değişken için öngörücü modeller kullanılmaktadır. Buna karşın incelenen ticari platformların büyük bölümü performans değerlendirme ve geri bildirim süreçlerine odaklanmakta, ileri düzey tahminleme yeteneklerini sınırlı ölçüde sunmaktadır.

Tablo ayrıca KUTUP'un departmana özgü KPI mimarisi açısından da farklılaştığını göstermektedir. Yazılım ve satış departmanları için geliştirilen performans göstergeleri, ilgili iş süreçlerinin karakteristik özelliklerini yansıtacak şekilde tasarlanmıştır. Böylece performans değerlendirme süreçlerinde daha bağlama duyarlı analizler gerçekleştirilebilmektedir.

Bir diğerk önemli farklılık ise sistemin açık kaynak teknolojiler kullanılarak geliştirilmiş olmasıdır. Ticari çözümler çoğunlukla kapalı kaynaklı SaaS platformları olarak sunulurken, KUTUP araştırma ve geliştirme çalışmalarına uygun esnek bir mimari sağlamaktadır. Ayrıca Docker Compose tabanlı dağıtım yapısı sayesinde sistemin farklı ortamlarda kurulumu ve yeniden üretilebilirliği kolaylaştırılmaktadır.

KUTUP'un dikkat çeken özelliklerinden biri de doğal dil işleme ve büyük dil modeli entegrasyonunu performans analitiğı süreçleriyle bütünleştirmesidir. Sistem, 360 derece geribildirimlerden elde edilen metinleri analiz etmekte ve makine öğrenmesi çıktılarını Google Gemini tabanlı yönetim raporlarına dönüştürebilmektedir. Bu yaklaşım, yalnızca sayısal performans değerlendirmesi yapmak yerine yöneticilere yorumlanabilir ve bağlamsal karar desteğı sunmaktadır.

Sonuç olarak KUTUP, performans yönetimi, öngörücü analitik, doğal dil işleme ve büyük dil modeli destekli raporlama bileşenlerini aynı platform içerisinde bir araya getiren bütünleşik bir karar destek sistemi olarak değerlendirilebilir. Bu özellikleri sayesinde sistem, geleneksel performans yönetimi çözümlerinin ötesine geçerek veri odaklı yönetim anlayışını destekleyen bir kurumsal performans analitiğı platformu niteliğı taşımaktadır.

2.7.1 Literatürdeki Boşluk ve KUTUP'un Konumlandırılması

Literatürde yer alan performans yönetimi sistemleri, çalışan analitiğı çözümleri ve kurumsal değerlendirme platformları incelendiğinde çalışmaların büyük bölümünün performans değerlendirme, çalışan bağlılığı ölçümü veya işten ayrılma tahmini gibi belirli problemlere odaklandığı görülmektedir. Benzer şekilde ticari yazılımlar da çoğunlukla hedef yönetimi, geri bildirim süreçleri ve performans raporlaması işlevlerini desteklemektedir. Bununla birlikte bu sistemlerin önemli bir kısmı performans göstergelerindeki zamansal değişimleri ayrıntılı biçimde modellememekte ve çalışan davranışlarını çok boyutlu olarak değerlendirebilecek öngörücü analitik mekanizmalarını sınırlı düzeyde kullanmaktadır.

Makine öğrenmesi temelli çalışmalar incelendiğinde ise işten ayrılma tahmini, tükenmişlik analizi veya performans değerlendirmesi gibi problemlerin çoğunlukla birbirinden bağımsız olarak ele alındığı görülmektedir. Ayrıca birçok araştırmada yapılandırılmış performans verileri kullanılmasına rağmen çalışan geri bildirimlerinden elde edilen yapılandırılmamış metin verilerinin karar destek süreçlerine entegrasyonu sınırlı düzeyde

kalmaktadır. Zaman serisi tabanlı özellik mühendisliği, doğal dil işleme çıktıları ve çok hedefli risk tahmin modellerinin aynı sistem içerisinde bütünlüklük biçimde kullanıldığı çalışmalar ise görece az sayıdadır.

Bu çalışma kapsamında geliştirilen KUTUP sistemi, söz konusu boşlukları gidermeyi hedefleyen bütünlüklük bir yaklaşım sunmaktadır. Sistem; departmana özgü KPI mimarisi, zaman serisi tabanlı performans modelleme, toplu öğrenme yöntemleri, doğal dil işleme teknikleri ve büyük dil modeli destekli raporlama mekanizmalarını tek bir platform altında bir araya getirmektedir. Böylece yalnızca mevcut performansın değerlendirilmesi değil; performans düşüşü, tükenmişlik riski, işten ayrılma riski ve yüksek risk durumu gibi geleceğe yönelik göstergelerin tahmin edilmesi de mümkün hâle gelmektedir.

KUTUP'un literatüre sunduğu temel katkılardan biri, yapılandırılmış performans verileri ile yapılandırılmamış metin verilerini aynı analitik çerçevede değerlendirmesidir. Sistem, KPI göstergelerinden elde edilen nicel bilgileri 360 derece geribildirimlerden elde edilen nitel verilerle birleştirerek daha kapsamlı bir performans değerlendirme yaklaşımı sunmaktadır. Ayrıca zaman serisi tabanlı özellik mühendisliği sayesinde çalışan performansının yalnızca mevcut durumu değil, zaman içerisindeki değişim eğilimleri de analiz edilebilmektedir.

Bir diğer önemli katkı ise makine öğrenmesi çıktılarının büyük dil modeli destekli açıklamalarla yöneticilere sunulmasıdır. Literatürde birçok çalışma yüksek doğruluklu tahmin modelleri geliştirmeye odaklanırken bu modellerin karar vericiler tarafından yorumlanabilirliği çoğu zaman ikinci planda kalmaktadır. KUTUP ise analitik çıktıları doğal dilde raporlayarak teknik sonuçların daha anlaşılır hâle getirilmesini amaçlamaktadır.

Sonuç olarak KUTUP; performans yönetimi, öngörücü analitik, doğal dil işleme ve büyük dil modeli destekli raporlama bileşenlerini bütünlüklük biçimde bir araya getiren bir kurumsal performans analitiği ve karar destek platformu olarak konumlandırılabilir. Bu yönüyle sistem, yalnızca mevcut performansını değerlendiren geleneksel çözümlerden ayrılarak veri odaklı ve proaktif yönetim anlayışını destekleyen bir yaklaşım sunmaktadır.

3.MATERYAL VE YÖNTEM

3.1 Kullanılan Teknolojiler

KUTUP sisteminin geliştirilmesinde web teknolojileri, makine öğrenmesi kütüphaneleri ve modern yazılım geliştirme araçlarından oluşan çok katmanlı bir teknoloji yığını kullanılmıştır. Teknoloji seçiminde performans, ölçeklenebilirlik, geliştirilebilirlik ve açık kaynak ekosistem desteği temel kriterler olarak dikkate alınmıştır. Sistem; arka uç servisleri, ön yüz kullanıcı arayüzü, veri tabanı altyapısı ve konteyner tabanlı dağıtım katmanlarından oluşmaktadır.

3.1.1 Arka Uç Teknoloji Yığını

Sistemin sunucu tarafı Python 3.10 programlama dili ve FastAPI 0.104.1 çerçevesi kullanılarak geliştirilmiştir. FastAPI son yıllarda yüksek performanslı web servislerinin geliştirilmesinde yaygın olarak tercih edilen modern bir Python çatısıdır. OpenAPI standardı ile uyumlu otomatik API dokümantasyonu üretmesi, asenkron işlem desteği sunması ve güçlü veri doğrulama mekanizmalarına sahip olması nedeniyle sistem gereksinimleri açısından uygun bir çözüm olarak değerlendirilmiştir.

FastAPI'nin temel avantajlarından biri, Python'un async/await yapısını doğrudan desteklemesidir. Bu özellik özellikle eş zamanlı API çağrıları, veritabanı işlemleri ve dış servis entegrasyonlarında sistem performansını artırmaktadır. Ayrıca Pydantic kütüphanesi aracılığıyla veri doğrulama işlemleri tip güvenli biçimde gerçekleştirilebilmekte ve istemci-sunucu arasındaki veri tutarlılığı korunabilmektedir.

Makine öğrenmesi katmanında scikit-learn temel öğrenme çerçevesi olarak kullanılmıştır. Satış departmanında kullanılan stacking mimarisinde LightGBM , XGBoost ve Random Forest algoritmalarından yararlanılmış; yazılım departmanında ise Random Forest tabanlı modeller tercih edilmiştir. Veri işleme ve özellik mühendisliği süreçlerinde pandas ve NumPy kütüphaneleri kullanılarak büyük veri kümeleri üzerinde etkin veri dönüşümü gerçekleştirilmiştir.

Kimlik doğrulama ve güvenlik işlemlerinde JWT tabanlı erişim mekanizması uygulanmıştır. Bu amaçla python-jose ve bcrypt kütüphaneleri kullanılarak güvenli oturum yönetimi ve parola karma işlemleri gerçekleştirilmiştir. Ayrıca Google Gemini API

entegrasyonu için httpx istemcisi kullanılmış, veritabanı şema yönetimi ise Alembic aracılığıyla sürdürülmüştür.

Kütüphane	Sürüm	Kullanım Amacı
FastAPI	0.104.1	RESTful API çerçevesi
Uvicorn	0.24.0	ASGI sunucu
SQLAlchemy	2.0.23	ORM ve veritabanı soyutlama katmanı
Pydantic	2.5.0	Şema doğrulama ve veri dönüşümü
scikit-learn	1.3.2	RF, LR, HGB, StackingClassifier
LightGBM	4.3.0	Stacking temel öğrenici (Satış)
XGBoost	2.0.3	Stacking temel öğrenici (Satış)
pandas / numpy	2.1.3 / 1.26.2	CSV/XLSX işleme, sayısal hesaplama
python-jose / bcrypt	3.3.0 / 3.1.7	JWT üretme ve parola karma
httpx / Alembic	0.25.2 / 1.12.1	Gemini API istemcisi, DB şema versiyonlama

Çizelge 3.1 Arka Uç Teknoloji Yığını

3.1.2 Ön Yüz Teknoloji Yığını

Kullanıcı ara yüzü geliştirme sürecinde Vue.js 3.4.0 ve TypeScript 5.3.0 teknolojileri tercih edilmiştir. Vue.js; bileşen tabanlı mimarisi, düşük öğrenme eğrisi ve yüksek performanslı reaktif yapısı nedeniyle modern tek sayfa uygulamalarında (Single Page Application – SPA) yaygın olarak kullanılmaktadır.

Sistem içerisinde kullanıcı oturumları, kimlik doğrulama bilgileri ve uygulama durumu Pinia durum yönetim kütüphanesi aracılığıyla merkezi olarak yönetilmektedir. Bu yaklaşım, farklı bileşenler arasında veri tutarlılığının korunmasına ve kullanıcı deneyiminin iyileştirilmesine katkı sağlamaktadır.

Arayüz tasarımı Tailwind CSS kullanılmıştır. Utility-first yaklaşımı sayesinde kullanıcı arayüzleri daha hızlı geliştirilebilmiş ve bileşenler arasında görsel tutarlılık sağlanmıştır. Veri görselleştirme işlemleri için Chart.js kütüphanesinden yararlanılmış ve

performans göstergeleri, risk analizleri ve zaman serisi verileri grafikler aracılığıyla sunulmuştur.

Geliştirme ortamında Vite derleme aracı tercih edilmiştir. Vite'in sunduğu hızlı derleme süreci ve Hot Module Replacement (HMR) desteği geliştirme verimliliğini artırmış ve kullanıcı arayüzü geliştirme sürecini hızlandırmıştır.

3.1.3 Veritabanı ve Altyapı

Sistemin kalıcı veri depolama katmanında PostgreSQL 15 ilişkisel veritabanı yönetim sistemi kullanılmıştır. PostgreSQL, açık kaynak yapısı, gelişmiş sorgulama yetenekleri ve yüksek güvenilirliği nedeniyle kurumsal uygulamalarda yaygın olarak tercih edilmektedir. Sistemde kullanıcı bilgileri, performans göstergeleri, risk analizleri, anket sonuçları ve geri bildirim kayıtları PostgreSQL üzerinde saklanmaktadır.

Veritabanı altyapısında pgvector eklentisi de etkinleştirilmiştir. Bu eklenti, gelecekte gerçekleştirilmesi planlanan anlamsal arama ve Retrieval-Augmented Generation (RAG) tabanlı uygulamalar için vektör veri saklama ve benzerlik arama desteği sağlamaktadır.

Sistemin dağıtımı Docker Compose tabanlı konteyner mimarisi kullanılarak gerçekleştirilmiştir. Bu yapı veritabanı, arka uç ve ön yüz servislerinin birbirinden bağımsız olarak çalıştırılmasına olanak sağlamaktadır. Konteyner tabanlı yaklaşım sayesinde geliştirme, test ve dağıtım ortamları arasında tutarlılık sağlanmış; kurulum ve bakım süreçleri kolaylaştırılmıştır.


Arka uç servisi özel olarak oluşturulan Python imajı üzerinde çalışırken ön yüz servisi Node.js tabanlı bir çalışma ortamında yürütülmektedir. Veritabanı katmanında ise pgvector destekli PostgreSQL imajı kullanılmaktadır. Ayrıca LightGBM algoritmasının paralel işlem gereksinimlerini karşılamak amacıyla gerekli sistem bağımlılıkları Docker yapılandırmasına dahil edilmiştir.

Bu teknoloji yığını sayesinde sistem; yüksek performanslı API servisleri, modern kullanıcı arayüzleri, ölçeklenebilir veri yönetimi ve taşınabilir dağıtım altyapısını bir arada sunabilen bütünleşik bir mimariye kavuşturulmuştur.

3.2 Sistem Mimarisi

KUTUP sistemi; sürdürülebilirlik, ölçeklenebilirlik ve bakım kolaylığı gereksinimleri dikkate alınarak üç katmanlı mimari (Three-Tier Architecture) yaklaşımı kullanılarak tasarlanmıştır. Üç katmanlı mimari; kullanıcı arayüzü, iş mantığı ve veri yönetimi bileşenlerinin birbirinden ayrılmasını sağlayarak sistemin daha modüler bir yapıda geliştirilmesine olanak tanımaktadır. Bu yaklaşım sayesinde her katman bağımsız olarak geliştirilebilmekte, test edilebilmekte ve gerektiğinde güncellenebilmektedir.

Sistemin genel mimarisi Şekil 3.1'de gösterilmektedir. Mimari yapı; Sunum Katmanı (Presentation Layer), Servis Katmanı (Service Layer) ve Veri ve Makine Öğrenmesi Katmanı (Data & Machine Learning Layer) olmak üzere üç temel bölümden oluşmaktadır.



Şekil 3.1. KUTUP Sistem Mimarisi

Sunum Katmanı

Sunum katmanı kullanıcıların sistem ile etkileşim kurduğu ön yüz bileşenlerini içermektedir. Bu katman Vue.js ve TypeScript teknolojileri kullanılarak geliştirilmiş olup tek sayfa uygulama (Single Page Application – SPA) mimarisine dayanmaktadır.

Sunum katmanında sistem yöneticisi, departman yöneticisi ve çalışan olmak üzere farklı kullanıcı gruplarına yönelik arayüzler bulunmaktadır. Admin paneli organizasyon genelindeki

performans ve risk analizlerinin görüntülenmesini sağlarken yönetici panelleri departman bazlı analizlerin gerçekleştirilmesine olanak tanımaktadır. Çalışan panelleri ise bireysel performans göstergeleri ve geri bildirimlerin görüntülenmesine yönelik olarak tasarlanmıştır.

Ön yüz uygulaması ile arka uç servisleri arasındaki iletişim HTTP tabanlı REST API çağrıları aracılığıyla gerçekleştirilmektedir. API isteklerinde kimlik doğrulama amacıyla JWT tabanlı belirteçler kullanılmakta ve yetkilendirme işlemleri istemci tarafında da doğrulanmaktadır. Böylece kullanıcıların yalnızca yetkili oldukları kaynaklara erişebilmeleri sağlanmaktadır.

Servis Katmanı

Servis katmanı sistemin iş mantığını içeren merkezi bileşendir. Bu katman FastAPI çerçevesi kullanılarak geliştirilmiş olup istemcilerden gelen isteklerin işlenmesinden sorumludur.

Servis katmanında kimlik doğrulama ve yetkilendirme işlemlerini gerçekleştiren Auth ve RBAC modülleri, makine öğrenmesi servisleri, doğal dil işleme servisleri, büyük dil modeli entegrasyon bileşenleri ve yardımcı servisler yer almaktadır. Bu yapı sayesinde sistem işlevleri birbirinden bağımsız modüller hâlinde yönetilebilmektedir.

Makine öğrenmesi servisleri performans düşüşü, tükenmişlik riski, işten ayrılma riski ve yüksek risk durumu tahminlerini gerçekleştirmektedir. NLP servisleri çalışan geri bildirimlerinden duygu analizi ve davranışsal göstergeler üretirken Gemini entegrasyonu bu çıktıları doğal dilde raporlara dönüştürmektedir.

FastAPI'nin bağımlılık enjeksiyonu (Dependency Injection) mekanizması kullanılarak servisler ile veri erişim katmanı arasındaki bağımlılık azaltılmıştır. Böylece bileşenlerin test edilebilirliği ve yeniden kullanılabilirliği artırılmıştır.

Veri ve Makine Öğrenmesi Katmanı

Veri ve makine öğrenmesi katmanı sistemin kalıcı veri depolama ve analitik işlemlerinden sorumludur. Bu katmanda PostgreSQL veritabanı, makine öğrenmesi model depoları, özellik mühendisliği bileşenleri ve veritabanı sürüm yönetim mekanizmaları yer almaktadır.

PostgreSQL veritabanı kullanıcı kayıtları, KPI verileri, anket sonuçları ve geri bildirim metinleri gibi operasyonel verileri saklamaktadır. SQLAlchemy ORM katmanı aracılığıyla uygulama nesneleri ile veritabanı tabloları arasında eşleme gerçekleştirilmekte ve veri erişim işlemleri güvenli biçimde yürütülmektedir.

Makine öğrenmesi bileşenleri içerisinde departmana özgü özellik üretim süreçleri yer almaktadır. Özellik mühendisliği katmanında lag, rolling ve trend tabanlı zaman serisi değişkenleri oluşturulmakta ve bu veriler model eğitim süreçlerinde kullanılmaktadır. Eğitilmiş modeller ise joblib formatında saklanarak yeniden kullanılabilir hâle getirilmektedir.

Ayrıca Alembic altyapısı kullanılarak veritabanı şemalarının sürüm yönetimi gerçekleştirilmekte ve sistem güncellemeleri sırasında veri bütünlüğünün korunması sağlanmaktadır.

Mimari Değerlendirme


Geliştirilen mimari yapı; kullanıcı arayüzü, iş mantığı ve veri yönetimi katmanlarını birbirinden ayırarak sistemin modülerliğini artırmaktadır. Bu yaklaşım sayesinde yeni departmanların sisteme eklenmesi, yeni makine öğrenmesi modellerinin geliştirilmesi veya kullanıcı arayüzünün güncellenmesi gibi işlemler diğer katmanlar üzerinde minimum etki oluşturmaktadır.

Bunun yanında Docker Compose tabanlı konteyner mimarisi sayesinde tüm bileşenler birbirinden bağımsız servisler olarak çalıştırılabilmekte ve geliştirme, test ve dağıtım süreçlerinde ortam tutarlılığı sağlanabilmektedir. Bu özellikler KUTUP'un araştırma amaçlı bir prototip olmanın ötesinde kurumsal kullanıma uygun genişletilebilir bir sistem mimarisi sunduğunu göstermektedir.

3.3 Veritabanı Tasarımı

KUTUP sisteminde kullanıcı yönetimi, performans göstergeleri, anket sonuçları, doğal dil işleme çıktıları ve makine öğrenmesi süreçlerinde kullanılan verilerin güvenli ve tutarlı biçimde saklanabilmesi amacıyla ilişkisel veritabanı yaklaşımı benimsenmiştir. Bu amaçla PostgreSQL 15 veritabanı yönetim sistemi kullanılmıştır.


Veritabanı tasarımında veri bütünlüğü, genişletilebilirlik ve performans kriterleri dikkate alınmıştır. Sistem kapsamında kullanıcı işlemleri, çalışan kayıtları, KPI tanımları, performans ölçümleri, anket sonuçları ve geri bildirim verileri birbirleriyle ilişkili tablolar üzerinde saklanmaktadır. Ayrıca makine öğrenmesi süreçlerinde kullanılan veri yükleme geçmişleri ve NLP analiz sonuçları için de ayrı tablolar oluşturulmuştur. Sistemin genel veri akışı Şekil 3.2'de gösterilmektedir.



Şekil 3.2. KUTUP Veri Akış Diyagramı

Şekilde görüldüğü üzere veri işleme süreci altı temel aşamadan oluşmaktadır. İlk aşamada CSV veya Excel formatındaki veri kümeleri sisteme yüklenmektedir. Daha sonra KPI kayıtları veritabanına aktarılmakta ve özellik mühendisliği süreçleri uygulanmaktadır. Oluşturulan özellikler kullanılarak makine öğrenmesi modelleri eğitilmekte ve tahmin işlemleri gerçekleştirilmektedir. Son aşamada ise makine öğrenmesi çıktıları, NLP analizleri ve nabız anketlerinden elde edilen göstergeler bütünlük risk skoruna dönüştürülerek kullanıcı panellerinde raporlanmaktadır.

Veritabanı yapısının kavramsal görünümü Şekil 3.3'te sunulmaktadır.



Şekil 3.3. Veritabanı Varlık-İlişki (ER) Diyagramı

Şekil 3.3. Veritabanı Varlık-İlişki (ER) Diyagramı incelendiğinde, sistemin temel varlıklarının kullanıcılar (users), çalışanlar (employees), departmanlar (departments), KPI tanımları (kpis), performans kayıtları (kpi_records), anket yanıtları (survey_responses), entegre geri bildirim ve analiz kayıtları (feedbacks_and_nlp) ile veri yükleme geçmişinden (data_uploads) oluştuğu görülmektedir. Bu yapılar arasında veritabanı mimarisinin gereksinimlerine göre bire-bir (one-to-one) ve bire-çok (one-to-many) ilişkiler kullanılarak veri tekrarının azaltılması ve veri bütünlüğünün korunması amaçlanmıştır.

Sistemde kullanıcı hesapları (users) ile çalışan kayıtları (employees) birbirinden bağımsız varlıklar olarak ayrılmış ve aralarında bire-bir bir ilişki kurulmuştur. Bu yaklaşım sayesinde kimlik doğrulama ve rol yönetim işlemleri ile çalışanların operasyonel performans verileri bağımsız biçimde yönetilebilmektedir. Her çalışan belirli bir departmana bağlı olarak

(departments) tanımlanmakta ve çalışanın kurum içindeki hedefleri ile ölçümleri kpis ve kpi_records tabloları üzerinden takip edilmektedir. Haftalık nabız ve motivasyon takibi ise survey_responses tablosuyla çalışan bazında saklanmaktadır. Böylece hem departman hem de çalışan düzeyinde çok boyutlu performans analizlerinin gerçekleştirilebilmesi mümkün olmaktadır.

Büyük dil modelleri (LLM) ve doğal dil işleme (NLP) süreçlerini sistem mimarisine entegre etmek amacıyla, klasik ve 360° geri bildirimler ile yapay zeka analiz çıktıları feedbacks_and_nlp adı verilen, birbiriyle yabancı anahtar (FK) ilişkisiyle bağlı çoklu tablolardan oluşan bir modül olarak tasarlanmıştır. Bu modül içerisinde text tabanlı geri bildirimler (feedbacks, feedback_responses) ayrı bir tabloda tutulurken; bu yanıtlardan üretilen duygu analizi skorları (sentiment_score), tükenmişlik riski (burnout_risk) ve işten ayrılma eğilimi (flight_risk) gibi model çıktıları ayrı bir feedback_nlp_analyses tablosunda, RAG (Retrieval-Augmented Generation) sistemine kaynaklık eden vektörel hafıza parçaları ise yine ayrı bir feedback_memory_chunks tablosunda ilgili geri bildirim ve çalışan kayıtlarına FK ile bağlanarak saklanmaktadır. Sistemde kullanılan temel tablolar ve görevleri Çizelge 3.2'de özetlenmektedir.

Tablo	Temel Alanlar	İşlev
<i>users</i>	id, email, hashed_password, role, is_active	Kimlik doğrulama ve yetkilendirme
<i>employees</i>	id, user_id, department_id, team, position, external_employee_code	Çalışan ana verisi ve organizasyonel pozisyon bilgileri
<i>departments</i>	id, name, description, department_key	Departman tanımları ve organizasyonel gruplama
<i>kpis</i>	id, name, unit, department_id, target_value	Departman bazlı performans göstergeleri (KPI) kataloğu
<i>kpi_records</i>	id, kpi_id, employee_id, value, period_date	Çalışanların dönem bazlı KPI ölçüm ve gerçekleştirme geçmişi
<i>survey_responses</i>	id, employee_id, score, ars_score, mte_score, comments	Haftalık nabız, motivasyon ve memnuniyet anket yanıtları
<i>feedbacks_and_nlp</i>	id, reviewer_id, reviewee_id, feedback_type, sentiment_score, burnout_risk, flight_risk, nlp_analysis_results, rag_memory_chunks	NLP analiz sonuçları
<i>data_uploads</i>	id, file_name, file_type, status, uploaded_by_id	Sisteme dışarıdan aktarılan CSV/XLSX veri kümelerinin yükleme geçmişi ve durum kontrolü

Çizelge 3.2. Veritabanı Temel Tablo Yapısı

Çizelge 3.2 incelendiğinde; kullanıcı yönetimi (*users*), organizasyonel yapılanma (*departments*, *employees*), performans ölçümü (*kpis*, *kpi_records*), anket süreçleri (*survey_responses*), gelişmiş geri bildirim analizi (*feedbacks_and_nlp*) ve sistem veri yükleme süreçlerinin (*data_uploads*) modüler tablolar aracılığıyla yürütüldüğü görülmektedir. Bu yaklaşım hem ilişkisel veritabanı modelindeki veri bütünlüğünü artırmakta hem de gelecekte sisteme eklenebilecek yeni fonksiyonel modüllerin entegrasyonunu kolaylaştırmaktadır.

Veritabanı tasarımında operasyonel güvenlik ve veri tutarlılığı üst düzeyde dikkate alınmıştır. Tablolar arasında kurulan birincil anahtar (PK) ve yabancı anahtar (FK) ilişkileri kullanılarak referans bütünlüğü (referential integrity) korunmuştur. Uygulama mimarisinde tercih edilen SQLAlchemy ORM katmanı sayesinde veritabanı üzerindeki tüm sorgular nesne ve parametre tabanlı olarak gerçekleştirilmektedir. Bu yapı, SQL enjeksiyonu (SQL Injection)

gibi yaygın siber güvenlik tehditlerine karşı veritabanı seviyesinde ek bir koruma kalkını sağlamaktadır.

Genel olarak değerlendirildiğinde geliştirilen veritabanı mimarisi; geleneksel performans yönetimi süreçlerinin yanı sıra, geri bildirim metinlerinden elde edilen duygu analizi skorları (sentiment_score), tükenmişlik riski (burnout_risk) ve işten ayrılma eğilimi (flight_risk) gibi metin analitiği (NLP) çıktılarını da başarıyla saklayabilecek şekilde tasarlanmıştır. Bu sayede platformun hem genişletilebilir hem de sürdürülebilir bir veri altyapısıyla çalışması güvence altına alınmıştır.

3.4 Yazılım Departmanı KPI Seti ve Eşik Değerleri

Yazılım geliştirme süreçlerinde çalışan performansının yalnızca tamamlanan görev sayısı veya üretilen kod miktarı üzerinden değerlendirilmesi yeterli değildir. Modern yazılım ekiplerinde performans; üretkenlik, kod kalitesi, iş yükü dengesi, ekip içi iş birliği, motivasyon düzeyi ve sürekli gelişim gibi çok sayıda faktörün birlikte ele alınmasını gerektirmektedir. Bu nedenle çalışma kapsamında yazılım departmanına özgü çok boyutlu bir performans değerlendirme çerçevesi oluşturulmuştur.

KPI setinin tasarımında çevik yazılım geliştirme (Agile Software Development), yazılım kalite ölçümleme (Software Metrics), örgütsel davranış ve performans yönetimi literatürü temel alınmıştır. Amaç yalnızca çalışanların mevcut performans seviyelerini ölçmek değil; aynı zamanda performans düşüşü, tükenmişlik ve işten ayrılma riski gibi durumları erken aşamada tespit edebilecek veri sinyalleri oluşturmaktır.

Bu kapsamda yazılım departmanı için toplam 20 KPI tanımlanmıştır. Göstergeler performansın farklı boyutlarını temsil edecek şekilde beş ana kategori altında sınıflandırılmıştır: Üretkenlik Göstergeleri, Kalite Göstergeleri, İş Yükü ve Sürdürülebilirlik Göstergeleri, Ekip Etkisi ve İş Birliği Göstergeleri, Üst Seviye Bileşik Göstergeler

Bu yapı sayesinde çalışan performansı yalnızca çıktı odaklı değil; davranışsal, organizasyonel ve sürdürülebilirlik boyutlarıyla birlikte değerlendirilebilmektedir.

3.4.1 KPI Eşik Değerlerinin Belirlenmesi

Performans göstergelerinin etkin biçimde kullanılabilmesi için yalnızca KPI tanımlarının oluşturulması yeterli değildir. KPI değerlerinin nasıl yorumlanacağı ve hangi

seviyelerde risk oluşturacağını da belirlenmesi gerekmektedir. Bu nedenle KUTUP sisteminde kullanılan eşik değerler üç temel kaynağın birlikte değerlendirilmesiyle oluşturulmuştur: akademik literatürde önerilen performans aralıkları, yazılım geliştirme süreçlerine ilişkin sektör uygulamaları, veri dağılımlarına dayalı istatistiksel değerlendirmeler.

Bu yaklaşım sayesinde eşik değerlerin yalnızca teorik varsayımlara dayanmasının önüne geçilmiş ve uygulama gerçekleriyle uyumlu bir performans değerlendirme modeli oluşturulmuştur.

Görev Tamamlama Oranı (GTO) için kullanılan %85 eşiği çevik yazılım geliştirme literatüründe sprint taahhütlerinin büyük bölümünün tamamlanmasının sağlıklı performans göstergesi olarak kabul edilmesine dayanmaktadır. Cohn ve Rubin, sprint planlama doğruluğu ile takım performansı arasında güçlü ilişki bulunduğunu belirtmektedir [10]; [28].

Bug Yoğunluğu (BY) ve Kritik Bug Oranı (KBO) göstergelerinde kullanılan eşikler ise yazılım kalite ölçümleme literatüründen yararlanılarak belirlenmiştir. Fenton ve Bieman ile Jones, hata yoğunluğunun yazılım kalitesi ve bakım maliyetleri üzerinde doğrudan etkili olduğunu göstermektedir [13]; [17].

İş Yüğü Endeksi (İYE) ve Sürekli Aşırı Yüğü Skoru (SAYS) göstergelerinde kullanılan sınır değerler, çalışma saatleri ile tükenmişlik arasındaki ilişkiyi inceleyen araştırmalara dayanmaktadır. WHO ve ILO tarafından yayımlanan raporlar ile Maslach vd.'nin tükenmişlik modeli yüksek iş yükünün çalışan performansı ve psikolojik iyi oluş üzerinde olumsuz etkiler oluşturabileceğini ortaya koymaktadır [25].

360 Derece Geri Bildirim Skoru, Motivasyon Skoru ve Motivasyon Trend Eğimi gibi davranışsal göstergelerde kullanılan eşikler ise çalışan bağlılığı ve organizasyonel davranış literatüründeki kabul görmüş değerlendirme aralıkları dikkate alınarak oluşturulmuştur.

Bu nedenle KPI eşikleri yalnızca sayısal sınırlar olarak değil, ilgili performans alanındaki akademik bulgular ve operasyonel ihtiyaçlar doğrultusunda oluşturulmuş karar destek mekanizmaları olarak değerlendirilmelidir.

3.4.2 Yazılım Departmanı KPI Kategorileri

Yazılım departmanına ait KPI'lar performansın farklı boyutlarını temsil edecek şekilde beş ana kategori altında gruplandırılmıştır.

Üretkenlik Göstergeleri

Bu kategoride çalışanın görevlerini tamamlama düzeyi, sprint hedeflerine uyumu ve takım içerisindeki görelî katkısı değerlendirilmektedir. Görev Tamamlama Oranı (GTO), Zamanında Teslim Oranı (ZTO), Görelî Katkı Endeksi (GKE) ve Kod Katkı Kalite Endeksi (KKKE) bu grupta yer almaktadır.

Kalite Göstergeleri

Kalite kategorisinde geliştirilen yazılımın hata düzeyi ve teknik kalite göstergeleri ölçülmektedir. Bug Yoğunluğu (BY), Kritik Bug Oranı (KBO), Code Review Kabul Oranı (CRKO) ve Ortalama PR Düzeltme Sayısı (OPDS) bu kapsamda kullanılmaktadır.

İş Yüğü ve Sürdürülebilirlik Göstergeleri

Bu kategoride çalışanın mevcut performansını hangi iş yüğü altında gerçekleştirdiğı değerlendirilmektedir. İş Yüğü Endeksi (İYE), Sürekli Aşırı Yüğü Skoru (SAYS) ve Toplantı Yüğü Oranı (TYO) göstergeleri tükenmişlik riskinin erken tespit edilmesine katkı sağlamaktadır.

Ekip Etkisi ve İş Birliğı Göstergeleri

Modern yazılım geliştirme süreçleri ekip çalışmasına dayanmaktadır. Bu nedenle Ekip Katkı Skoru (EKS), 360 Derece Geri Bildirim Skoru (360-GBS), Organizasyonel Merkezilik Skoru (OMS), Motivasyon Skoru (MS), Motivasyon Trend Eğimi (MTE) ve Gelişim Katılım Skoru (GKS) performans değerlendirme sürecine dahil edilmiştir.

Üst Seviye Bileşik Göstergeler

Çok sayıda KPI'nın yöneticiler tarafından daha kolay yorumlanabilmesi amacıyla Genel Performans Skoru (GPS), Ayrılma Riski Skoru (ARS) ve Potansiyel Performans Endeksi (PPE) gibi üst seviye bileşik göstergeler oluşturulmuştur. Bu göstergeler farklı performans boyutlarını tek bir skor altında birleştirerek karar verme sürecini kolaylaştırmaktadır.

No	Kod	Formül / Tanım	Eşik Değerleri	Gereççe
KPI-1	GTO	Tamamlanan Görev / Atanan Görev	≥ 0.85 Yüksek / $0.65 - 0.84$ Normal / < 0.65 Riskli	Agile commitment fulfillment [10]
KPI-2	ZTO	Deadline öncesi tamamlanan / Toplam görev	≥ 0.80 İyi / $0.60 - 0.79$ Orta / < 0.60 Risk	Sprint planlama doğruluğu [28]
KPI-3	GKE	Kişi story point / Takım ort. story point	$> +1\sigma$ Yüksek / $\pm 1\sigma$ Dengeli / $< -1\sigma$ Düşük	Takım adaptif; görelî ölçüm
KPI-4	KKKE	$ECO \times 0.35 + CTONorm \times 0.25 + OCHnorm \times 0.20 + HDS \times 0.20$	≥ 0.80 Sağlıklı / $0.60 - 0.79$ Orta / < 0.60 Riskli	Commit kalitesi bileşik endeksi
KPI-5	BY	Toplam bug / 1.000 satır kod	≤ 0.3 İyi / $0.3 - 0.6$ Kabul. / > 0.6 Risk	Yazılım kalite metrikleri [13]
KPI-6	KBO	Kritik bug / Toplam bug	< 0.20 Sağlıklı / $0.20 - 0.35$ Dikkat / > 0.35 Risk	Kalite kırmızı çizgisi (Jones, 2008)
KPI-7	CRKO	İlk seferde kabul edilen PR / Toplam PR	≥ 0.75 Yüksek / $0.55 - 0.74$ Orta / < 0.55 Düşük	Teknik standart kalitesi
KPI-8	OPDS	Toplam review düzeltme / Toplam PR	≤ 2 Temiz / $3 - 4$ Kabul. / ≥ 5 Eğitim ihtiyacı	PR kalite göstergesi
KPI-9	İYE	Fiili çalışma saati / 40	$0.9 - 1.1$ Dengeli / $1.1 - 1.3$ Yüksek / > 1.3 Burnout	WHO/ILO iş yükü literatürü [25]
KPI-10	SAYS	Son 6 haftada İYE > 1.2 olan hafta sayısı	≤ 1 Normal / $2 - 3$ Risk / ≥ 4 Kritik	Kronik yük tespiti [7]
KPI-11	TYO	Toplantı süresi / Toplam çalışma süresi	≤ 0.25 Verimli / $0.25 - 0.40$ Dikkat / > 0.40 Risk	Deep work kapasitesi
KPI-12	EKS	(Review + Mentorluk + Yardım) / Sprint	Takım ort. Yüksek / $< \text{Ortalama}$ Düşük	Organizasyonel iş birliği
KPI-13	360-GBS	$0.4 \times \text{Peer} + 0.4 \times \text{Manager} + 0.2 \times \text{Self}$ (0–100)	≥ 80 Güçlü / $65 - 79$ Orta / < 65 Gelişim	Çok kaynaklı geribildirim [1]
KPI-14	OMS	Organizasyonel ağ merkezilik skoru $\in [0,1]$	> 0.6 Hub / $0.3 - 0.6$ Normal / < 0.3 İzole	Network science [3]
KPI-15	MS	$(\text{Ort. nabız puanı} / 5) \times 100$ [%70 yanıt şartı]	≥ 75 Yüksek / $55 - 74$ Orta / < 55 Risk	Ayrılma risk korelasyonu [15]
KPI-16	MTE	Son 4 haftalık motivasyon doğrusal eğimi	> 0 Artan / ≈ 0 Stabil / < 0 Düşüş	Trend erken uyarı sinyali
KPI-17	GKS	Tamamlanan gelişim aktivitesi / Önerilen	≥ 0.70 İyi / $0.40 - 0.69$ Orta / < 0.40 Düşük	Öğrenme potansiyeli göstergesi
KPI-18	GPS	$0.30 \times \text{Üretk.} + 0.25 \times \text{Kalite} + 0.20 \times \text{Ekip} + 0.15 \times \text{Mot.} + 0.10 \times \text{Sürd.}$	≥ 80 Yüksek / $65 - 79$ Stabil / < 65 Riskli	Bileşik genel performans
KPI-19	ARS	ML modeli tahmini $\in [0,1]$	< 0.30 Düşük / $0.30 - 0.60$ Orta / > 0.60 Yüksek	İstifa riski tahmini
KPI-20	PPE	Öğrenme Hızı + Geribildirim + Trend bileşimi	≥ 75 Yüksek / $60 - 74$ Orta / < 60 Düşük	Potansiyel performans endeksi

Çizelge 3.3. Yazılım Departmanı KPI Seti ve Eşik Değerleri

Çizelge 3.3 incelendiğinde KPI'ların yalnızca çıktı odaklı performans ölçümlerinden oluşmadığı görülmektedir. Görev tamamlama oranı, hata yoğunluğu ve kod kalite göstergeleri gibi teknik metriklerin yanında motivasyon seviyesi, organizasyonel ağ merkeziliyeti, gelişim faaliyetleri ve 360 derece geri bildirimlerden elde edilen davranışsal göstergeler de değerlendirme sürecine dahil edilmiştir.

Özellikle İYE, SAYS ve MTE gibi göstergeler yalnızca mevcut performansın ölçülmesi amacıyla değil, gelecekte ortaya çıkabilecek tükenmişlik ve işten ayrılma risklerinin öngörülmesi amacıyla tasarlanmıştır. Bu yaklaşım performans yönetiminin yalnızca geçmiş sonuçları değerlendiren bir yapı olmaktan çıkarılarak öngörücü analitik yaklaşımına yaklaştırılmasını sağlamaktadır.

GPS, ARS ve PPE gibi bileşik göstergeler ise farklı KPI'ların tek bir skor altında birleştirilmesine olanak tanımakta ve yöneticilerin performans eğilimlerini daha hızlı yorumlayabilmesine katkı sağlamaktadır.

Genel olarak değerlendirildiğinde geliştirilen KPI mimarisi, yazılım geliştirme süreçlerinde performansın teknik, davranışsal ve organizasyonel boyutlarını birlikte ele alan bütünsel bir değerlendirme çerçevesi sunmaktadır.

3.5 Satış Departmanı KPI Seti ve Eşik Değerleri

Satış ekiplerinin performansı, yazılım geliştirme ekiplerinden farklı olarak doğrudan gelir üretimi, müşteri ilişkileri yönetimi ve fırsat dönüşüm süreçleriyle ilişkilidir. Bu nedenle satış çalışanlarının performansının yalnızca toplam satış miktarı üzerinden değerlendirilmesi yeterli değildir. Modern satış yönetimi yaklaşımları; satış hacmi, müşteri kazanımı, dönüşüm oranları, müşteri memnuniyeti, ekip iş birliği ve sürdürülebilir performans göstergelerinin birlikte değerlendirilmesini önermektedir [16].

Bu çalışma kapsamında geliştirilen KUTUP sisteminde satış departmanı için toplam 25 KPI tanımlanmıştır. KPI seti oluşturulurken satış yönetimi, müşteri ilişkileri yönetimi (CRM), satış analitiği ve örgütsel davranış literatüründen yararlanılmıştır. Amaç yalnızca satış sonuçlarını ölçmek değil; performans düşüşü, tükenmişlik riski ve işten ayrılma riski gibi durumları önceden tespit edebilecek veri sinyalleri oluşturmaktır.

Satış KPI'ları performansın farklı boyutlarını temsil edecek şekilde aşağıdaki tematik kategoriler altında gruplandırılmıştır:

Bu yapı sayesinde satış performansı yalnızca gelir odaklı değil; müşteri ilişkileri, süreç kalitesi ve sürdürülebilirlik boyutlarıyla birlikte değerlendirilmektedir.

- Satış Sonuçları ve Hedef Gerçekleşme Göstergeleri
- Müşteri Dönüşüm ve Fırsat Yönetimi Göstergeleri
- İş Yüğü ve Sürdürülebilirlik Göstergeleri
- Müşteri Memnuniyeti ve Kalite Göstergeleri
- Ekip İş Birliği ve Davranışsal Göstergeler
- Üst Seviye Bileşik Performans Göstergeleri

3.5.1 KPI Eşik Değerlerinin Belirlenmesi

Satış performans göstergelerinin yorumlanabilmesi için her KPI için belirli performans aralıkları tanımlanmıştır. Eşik değerlerin oluşturulmasında üç temel kaynak birlikte değerlendirilmiştir:

Satış yönetimi literatüründe raporlanan performans seviyeleri,
CRM ve satış dönüşüm araştırmalarında önerilen sektör standartları,
Veri dağılımlarına dayalı istatistiksel analizler.

Bu yaklaşım sayesinde KPI eşiklerinin yalnızca teorik varsayımlara dayanmasının önüne geçilmiş ve satış süreçlerinin operasyonel gerçekliğiyle uyumlu bir değerlendirme çerçevesi oluşturulmuştur.

Örneğin Satış Hedef Gerçekleşme Oranı (SHGO) göstergesinde %100 ve üzeri değerler hedeflerin aşıldığını gösterirken, %75'in altındaki değerler performans riski olarak değerlendirilmiştir. Bu eşikler satış performansı literatüründe yaygın olarak kullanılan hedef gerçekleşme analizleriyle uyumludur [16].

Lead Dönüşüm Oranı (LMDO) ve Teklif Kazanma Oranı (TKO) göstergelerinde kullanılan eşikler ise satış hunisi (sales funnel) ve dönüşüm yönetimi araştırmalarında raporlanan ortalama başarı oranlarından yararlanılarak belirlenmiştir [31].

Pipeline Sağlık Oranı (PSO), Yaşlı Fırsat Oranı (PYO) ve CRM Disiplini (CRMD) gibi göstergeler satış sürecinin sürdürülebilirliğini ölçmektedir. Bu göstergelerde kullanılan sınır değerler CRM uygulamalarında önerilen fırsat yönetimi prensipleri dikkate alınarak oluşturulmuştur.

Müşteri Memnuniyeti (CSAT) ve Şikâyet Oranı (ŞO) göstergeleri ise müşteri deneyimi literatüründe yaygın olarak kullanılan kalite ölçütlerine dayanmaktadır. Bu göstergeler satış sonuçlarının yanında müşteri ilişkilerinin kalitesini de değerlendirme sürecine dahil etmektedir.

Davranışsal göstergeler olan 360 Derece Satış Geri Bildirim Skoru (360-SGS), Motivasyon Skoru (MS-S) ve Motivasyon Trend Eğimi (MTE-S) ise çalışan bağlılığı ve organizasyonel davranış çalışmalarında önerilen değerlendirme yaklaşımları temel alınarak oluşturulmuştur.

Bu nedenle KPI eşikleri yalnızca performans sınıflandırması amacıyla değil, aynı zamanda performans düşüşü ve risk oluşumuna ilişkin erken uyarı mekanizması olarak kullanılmaktadır.

3.5.2 Satış Departmanı KPI Kategorileri

a) Satış Sonuçları ve Hedef Gerçekleşme Göstergeleri:

Bu kategoride satış çalışanlarının doğrudan iş sonuçları değerlendirilmektedir. Satış Hedef Gerçekleşme Oranı (SHGO), Ortalama Satış Değeri (OSD) ve Gelir Katkı Payı (GKP) göstergeleri bireysel satış başarısını ölçmektedir.

b) Müşteri Dönüşüm ve Fırsat Yönetimi Göstergeleri:

Satış süreçlerinin etkinliği yalnızca satış miktarıyla değil, fırsatların müşteriye dönüştürülme başarısıyla da ilişkilidir. Yeni Müşteri Kazanım Oranı (NMKO), Lead Dönüşüm Oranı (LMDO), Teklif Kazanma Oranı (TKO), Pipeline Sağlık Oranı (PSO) ve Yaşlı Fırsat Oranı (PYO) bu amaçla kullanılmaktadır.

c) İş Yüğü ve Sürdürülebilirlik Göstergeleri:

Satış ekiplerinde aşırı iş yükü uzun vadede performans kaybına ve tükenmişlik riskine yol açabilmektedir. Satış İş Yüğü Endeksi (SİYE) ve Sürekli Aşırı Yük Skoru (SAYS-S) göstergeleri bu risklerin izlenmesini sağlamaktadır.

d) Müşteri Memnuniyeti ve Kalite Göstergeleri:

Müşteri Memnuniyet Skoru (CSAT), Şikâyet Oranı (ŞO) ve CRM Disiplini (CRMD) göstergeleri satış performansının kalite boyutunu temsil etmektedir. Böylece yalnızca satış miktarı değil, satışın sürdürülebilirliği de değerlendirilebilmektedir.

e)Ekip İş Birliği ve Davranışsal Göstergeler:

Satış Ekip Katkı Skoru (SEKS), 360 Derece Satış Geri Bildirim Skoru (360-SGS), Motivasyon Skoru (MS-S), Motivasyon Trend Eğimi (MTE-S) ve Gelişim Katılım Skoru (GKS-S) çalışanların ekip içerisindeki katkısını ve gelişim eğilimini ölçmektedir.

Üst Seviye Bileşik Göstergeler:

Satış Genel Performans Skoru (SGPS), Ayrılma Riski Skoru (ARS-S) ve Potansiyel Satış Performans Endeksi (PSPE) çok sayıda KPI'nın yöneticiler tarafından daha kolay yorumlanabilmesi amacıyla oluşturulmuş bileşik göstergelerdir.

No	Kod	Formül / Tanım	Eşik Değerleri	Gerekçe
KPI-1	SHGO	Gerçekleşen satış tutarı / Hedef satış tutarı	≥ 1.00 Aşıldı / $0.75-0.99$ Yakın / <0.75 Risk	Temel satış çıktı ölçütü [16]
KPI-2	SAY	Toplam aktivite (arama+e-posta+toplantı+teklif+takip) / Çalışma günü	Takım ort. üstü / civarı / altı	Aktivite tabanlı satış verimliliği
KPI-3	NMKO	Yeni müşteri / Toplam kazanılan müşteri	≥ 0.40 Güçlü / $0.20-0.39$ Orta / <0.20 Bağımlı	Portföy büyüme kapasitesi
KPI-4	LMDO	Kazanılan müşteri / Toplam lead	≥ 0.25 Güçlü / $0.10-0.24$ Orta / <0.10 Düşük	Dönüşüm etkinliği [31]
KPI-5	TKO	Kazanılan teklif / Toplam teklif	≥ 0.40 Güçlü / $0.20-0.39$ Orta / <0.20 Düşük	Teklif kalite ve kapanış becerisi
KPI-6	OSDS	Ortalama (kapanış tarihi – ilk temas tarihi) [gün]	Takım ort. altı / üstü (bağılamsal)	Süreç hızı ve kalite dengesi
KPI-7	OSD	Toplam satış tutarı / Kazanılan satış sayısı	Takım ort. üstü / civarı / altı	Satış değer segmentasyonu
KPI-8	GKP	Kişi satış geliri / Takım toplam satış geliri	Takım ort. üstü / civarı / altı	Gelir katkı endeksi (GKE analogu)
KPI-9	UCO	Ek satış geliri (upsell+cross-sell) / Toplam satış	≥ 0.25 Güçlü / $0.10-0.24$ Orta / <0.10 Zayıf	Müşteri yaşam boyu değeri
KPI-10	PSO	Açık fırsat değeri / Dönem satış hedefi	≥ 3.0 Sağlıklı / $2.0-2.99$ Orta / <2.0 Risk	Pipeline kapsama oranı ($3\times$ kural)
KPI-11	PYO	Yaşlı fırsat ($>1.5\times$ ort. döngü) / Toplam açık fırsat	≤ 0.20 Sağlıklı / $0.21-0.40$ Dikkat / >0.40 Tıkanık	Pipeline kalite göstergesi
KPI-12	SİYE	Aktif lead sayısı / Takım ortalama aktif lead	$0.80-1.20$ Dengeli / $1.21-1.50$ Yüksek / >1.50 Aşırı	Bireysel kapasite yönetimi
KPI-13	SAYS-S	Son 6 haftada SİYE >1.2 olan hafta sayısı	≤ 1 Normal / $2-3$ Risk / ≥ 4 Kritik	Kronik yük tespiti

KPI-14	TDO	Zamanında takip edilen / Takip gerektiren fırsat	≥ 0.85 Güçlü / $0.65-0.84$ Orta / <0.65 Problem	Satış döngü disiplini
KPI-15	CSAT	$(\text{Ort. müşteri puanı} / 5) \times 100$	≥ 80 Yüksek / $60-79$ Orta / <60 Risk	Müşteri deneyimi kalitesi
KPI-16	ŞO	Şikâyet sayısı / Toplam satış sayısı	≤ 0.05 Sağlıklı / $0.06-0.10$ Dikkat / >0.10 Risk	Satış kalitesi kırmızı çizgisi
KPI-17	CRMD	Güncel CRM kaydı / Toplam işlem sayısı	≥ 0.85 Güçlü / $0.65-0.84$ Orta / <0.65 Risk	Model veri kalitesi (ML için kritik)
KPI-18	SEKS	Lead paylaşımı + Ortak satış + Mentorluk	Takım ort. üstü / civarı / altı	Ekip sinerji göstergesi
KPI-19	360-SGS	$0.4 \times \text{Yönetici} + 0.4 \times \text{Ekip} + 0.2 \times \text{Öz}$ (0–100)	≥ 80 Güçlü / $65-79$ Orta / <65 Gelişim	Çok kaynaklı satış performansı
KPI-20	MS-S	$(6 \text{ ay ort. nabız puanı} / 5) \times 100$ [%70 yanıt şartı]	≥ 75 Yüksek / $55-74$ Orta / <55 Risk	Yazılım MS analogu
KPI-21	MTE-S	Son 4 haftanın motivasyon doğrusal eğimi	>0 Artan / ≈ 0 Stabil / <0 Düşüş	Trend erken uyarı
KPI-22	GKS-S	Tamamlanan gelişim aktivitesi / Önerilen	≥ 0.70 İyi / $0.40-0.69$ Orta / <0.40 Düşük	Kariyer gelişim eğilimi
KPI-23	SGPS	$0.30 \times \text{Üretk.} + 0.25 \times \text{Dönüşüm} + 0.20 \times \text{Gelir} + 0.15 \times \text{Müş.} + 0.10 \times \text{Süred.}$	≥ 80 Yüksek / $65-79$ Stabil / <65 Riskli	Bileşik satış performansı
KPI-24	ARS-S	ML modeli tahmini $\in [0,1]$	<0.30 Düşük / $0.30-0.60$ Orta / >0.60 Yüksek	Satış istifa riski tahmini
KPI-25	PSPE	Aktivite+Dönüşüm trend+Gelişim+360 bileşimi	≥ 75 Yüksek / $60-74$ Orta / <60 Düşük	Potansiyel çalışan tespiti

Çizelge 3.4. Satış Departmanı KPI Setinin Tam Tanımları

Çizelge 3.4 incelendiğinde satış performansının yalnızca satış miktarı veya gelir üretimi üzerinden değerlendirilmediği görülmektedir. Müşteri kazanımı, dönüşüm başarısı, müşteri memnuniyeti, ekip katkısı, motivasyon düzeyi ve gelişim faaliyetleri gibi farklı boyutlar birlikte ele alınmıştır.

Özellikle PSO, PYO ve CRMD gibi göstergeler satış sonuçlarından önce gelen süreç kalitesini ölçerken; MS-S, MTE-S ve ARS-S gibi göstergeler gelecekte ortaya çıkabilecek performans ve bağlılık risklerinin öngörülmesine katkı sağlamaktadır. SGPS ve PSPE gibi bileşik göstergeler ise yöneticilerin çok sayıda performans değişkenini tek bir skor üzerinden değerlendirebilmesine olanak tanımaktadır.

Bu yönüyle geliştirilen satış KPI mimarisi, satış performansını finansal, operasyonel ve davranışsal boyutlarıyla birlikte değerlendiren bütünlük bir performans ölçüm çerçevesi sunmaktadır.


3.6 Makine Öğrenmesi Pipeline'ı

3.6.1 Genel İş Akışı

Makine öğrenmesi projelerinde model başarısını belirleyen en önemli unsurlardan biri, verinin işleme biçimi ve modelleme sürecinin sistematik olarak yönetilmesidir. Ham verinin doğrudan modele verilmesi çoğu zaman yeterli sonuç üretmemekte; veri temizleme, özellik mühendisliği, model eğitimi ve performans değerlendirme aşamalarının bütünlük şekilde tasarlanmasını gerektirmektedir [22].

Bu çalışma kapsamında geliştirilen KUTUP sisteminde makine öğrenmesi süreci yeniden üretilebilir, genişletilebilir ve departman bağımsız çalışabilecek şekilde tasarlanmıştır. Sistemde kullanılan makine öğrenmesi iş akışı beş temel aşamadan oluşmaktadır:

1. Veri yükleme
2. Özellik mühendisliği
3. Model eğitimi
4. Model değerlendirme
5. Tahmin ve risk skrolama



Şekil 3.4'te KUTUP sisteminde kullanılan makine öğrenmesi pipeline mimarisi gösterilmektedir.

Veri yükleme aşamasında yönetici tarafından sisteme yüklenen CSV veya XLSX formatındaki veri kümeleri doğrulanmakta ve veri tabanına kaydedilmektedir. Bu aşamada kolon isimleri normalize edilmekte, eksik alanlar kontrol edilmekte ve departmana özgü veri yapısına uygunluk doğrulanmaktadır.

Özellik mühendisliği aşamasında ham KPI verilerinden makine öğrenmesi modellerinin kullanabileceği yeni değişkenler türetilmektedir. Bu aşama sistemin en kritik bileşenlerinden biri olup çalışan davranışlarının zamansal değişimini temsil eden ek özelliklerin oluşturulmasını sağlamaktadır.

Model eğitimi aşamasında departmana özgü öğrenme mimarileri kullanılmaktadır. Yazılım departmanında Random Forest algoritması tercih edilirken satış departmanında LightGBM, XGBoost ve Random Forest modellerinin birleştirildiği stacking tabanlı bir ensemble mimarisi kullanılmaktadır.

Model değerlendirme aşamasında zaman sıralamasına duyarlı eğitim-test ayrımı uygulanmaktadır. Böylece gelecekteki verilerin geçmişe sızması engellenmekte ve gerçek kullanım senaryolarına daha yakın sonuçlar elde edilmektedir. Son aşamada ise eğitilen modeller kullanılarak çalışan bazlı risk tahminleri üretilmekte ve sonuçlar bütünsel risk skoru hesaplamasında kullanılmaktadır.

3.6.2 Özellik Mühendisliği

Özellik mühendisliği (feature engineering), ham verilerin makine öğrenmesi algoritmaları tarafından daha etkin kullanılabilmesini sağlayan dönüşüm süreci olarak tanımlanmaktadır. Literatürde model performansını artıran en önemli faktörlerden birinin uygun özellik tasarımı olduğu belirtilmektedir [11].

KUTUP sisteminde kullanılan özellik mühendisliği yaklaşımı yalnızca mevcut KPI değerlerini değil, bu göstergelerin zaman içerisindeki davranışlarını da temsil etmeyi amaçlamaktadır. Böylece çalışan performansındaki eğilimlerin ve değişim yönlerinin modellere yansıtılması hedeflenmiştir.

a) *Yazılım Departmanı Özellik Mimarisi*

Yazılım departmanı için geliştirilen SoftwareFeatureBuilder bileşeni toplam 20 temel KPI üzerinden çalışmaktadır.

Bu bileşen tarafından oluşturulan özellikler dört ana grupta toplanmaktadır:

- Doğrudan KPI değişkenleri
- Zamansal özellikler
- Döngüsel zaman kodlamaları
- Çalışan bağlam özellikleri

Doğrudan KPI değişkenleri performans değerlendirme sürecinde kullanılan 20 temel göstergeden oluşmaktadır.

Haftalık verilerin mevsimsellik etkilerini temsil edebilmesi amacıyla hafta bilgisi sinüs ve kosinüs dönüşümleriyle kodlanmaktadır:

$$\text{week}_{\sin} = \sin\left(\frac{2\pi \cdot \text{week}}{52}\right)$$
$$\text{week}_{\cos} = \cos\left(\frac{2\pi \cdot \text{week}}{52}\right)$$

Bu yöntem zaman değişkenlerinin doğrusal olmayan döngüsel yapısının modele aktarılmasını sağlamaktadır. Her KPI için ayrıca üç farklı zaman serisi türevi oluşturulmaktadır:

- *lag_1*: Önceki haftadaki KPI değeri
- *rolling_4*: Son dört haftanın hareketli ortalaması
- *trend_4*: Mevcut KPI değerinin son dört haftanın hareketli ortalamasından sapması

Bu özellikler çalışan performansındaki yön değişimlerinin modellenmesine katkı sağlamaktadır. Bunlara ek olarak;

- deneyim yılı (experience_years),
- takım bilgisi (team),
- rol seviyesi (role)

gibi bağlamsal değişkenler de modele dahil edilmektedir.

b) Satış Departmanı Özellik Mimarisi

Satış departmanında kullanılan veri yapısı daha fazla operasyonel değişken içerdiğinden özellik mühendisliği süreci daha kapsamlıdır.

SalesFeatureBuilder bileşeni toplam 25 KPI ve bunlardan türetilen değişkenlerle birlikte yaklaşık 114 özellik üretmektedir.

Temel KPI değişkenlerine ek olarak çeşitli oran bazlı göstergeler hesaplanmaktadır. Bunlardan bazıları şunlardır:

- Satış Hedef Gerçekleşme Oranı (SHGO)
- Lead Dönüşüm Oranı (LMDO)
- Kazanım Oranı (Win Rate)
- Takım Karşılaştırmalı Gelir Oranı
- İş Yüğü Aşım Endeksi

Örneğin satış hedef gerçekleşme oranı aşağıdaki şekilde hesaplanmaktadır:

$$SHGO = \frac{\text{Gerçekleşen Satış}}{\text{Hedef Satış}}$$

Benzer şekilde müşteri dönüşüm başarısını temsil eden lead dönüşüm oranı aşağıdaki formülle hesaplanmaktadır:

$$LMDO = \frac{\text{Kazanılan Müşteri}}{\text{Toplam Lead}}$$

Satış verilerinde de yazılım departmanında kullanılan lag, rolling ve trend tabanlı zaman serisi özellikleri oluşturulmaktadır. Özellikle gelir trendleri ve motivasyon eğilimleri çalışan performansındaki değişimlerin erken aşamada belirlenmesine katkı sağlamaktadır.

Literatürde zaman serisi tabanlı özelliklerin statik özelliklere kıyasla daha yüksek tahmin performansı sağlayabildiği gösterilmiştir [8]. KUTUP sisteminde kullanılan trend ve hareketli ortalama özellikleri bu bulgular doğrultusunda tasarlanmıştır.

3.6.3 Model Seçimi ve Bütünleşik Risk Skoru

Makine öğrenmesi projelerinde model seçimi, veri yapısının özellikleri, yorumlanabilirlik gereksinimleri ve tahmin performansı gibi kriterler dikkate alınarak gerçekleştirilmektedir. Bu çalışmada kullanılan veri kümeleri hem sayısal performans

göstergelerini hem de zaman serisi türevlerini içermektedir. Bu nedenle doğrusal olmayan ilişkileri modelleyebilen ve karmaşık örüntüleri öğrenebilen algoritmalar tercih edilmiştir.

Çalışma kapsamında farklı algoritmalar üzerinde deneyler gerçekleştirilmiş ve elde edilen sonuçlar doğrultusunda yazılım ve satış departmanları için farklı model mimarileri benimsenmiştir. Kullanılan modeller ve temel hiperparametreleri Çizelge 3.5'te gösterilmektedir.

Model	Hiperparametreler	Departman / Rol
Random Forest (RF)	n_estimators=250, min_samples_leaf=2, class_weight=balanced	Yazılım (birincil), Satış (yedek)
Histogram GB (HGB)	learning_rate=0.06, max_iter=150	Yazılım (seçenek)
LightGBM	n_estimators=150, learning_rate=0.05, num_leaves=31	Satış (temel öğrenici)
XGBoost	n_estimators=150, learning_rate=0.05, max_depth=5	Satış (temel öğrenici)
Lojistik Regresyon	class_weight=balanced, max_iter=1000	Meta-öğrenici (Satış stacking)
Stacking LGB+XGB+RF→LR	cv=3, passthrough=False	Satış (birincil mimari)

Çizelge 3.5. Eğitimde Kullanılan ML Modelleri ve Hiperparametreleri

Yazılım departmanı veri setinde gerçekleştirilen ön değerlendirmeler sonucunda Random Forest algoritmasının doğruluk, kararlılık ve yorumlanabilirlik açısından en uygun çözümü sunduğu görülmüştür. Random Forest yöntemi, çok sayıda karar ağacının sonuçlarını birleştirerek tek bir karar ağacına kıyasla daha düşük varyans ve daha yüksek genelleme performansı elde etmektedir [4]. Ayrıca veri kümesindeki doğrusal olmayan ilişkileri başarılı biçimde modelleyebilmesi ve sınıf dengesizliğine karşı dayanıklı yapısı nedeniyle yazılım departmanı için birincil model olarak tercih edilmiştir.

Satış departmanında ise veri yapısının daha karmaşık olması ve çok sayıda etkileşimli değişken içermesi nedeniyle stacking tabanlı bir ensemble mimarisi kullanılmıştır. Bu mimaride LightGBM, XGBoost ve Random Forest algoritmaları temel öğreniciler olarak görev yapmakta; bu modellerin tahminleri ikinci seviyede Lojistik Regresyon tarafından birleştirilmektedir. Böylece farklı algoritmaların güçlü yönlerinden aynı anda yararlanılması amaçlanmıştır.

Şekil 3.3'te gösterilen mimaride satış departmanı için kullanılan stacking yaklaşımı, farklı hata yapılarına sahip modellerin bir araya getirilmesi sayesinde tek bir modele göre daha yüksek genelleme performansı elde edilmesini sağlamaktadır. Literatürde ensemble yöntemlerinin özellikle karmaşık sınıflandırma problemlerinde daha başarılı sonuçlar üretebildiği belirtilmektedir [8] , 2016; [21]

Bu çalışma kapsamında her departman için dört farklı hedef değişken ayrı ikili sınıflandırma problemi olarak ele alınmıştır:

- Performans Düşüşü Riski
- Tükenmişlik Riski
- İstifa Riski
- Yüksek Risk Durumu

Bu yaklaşım sayesinde her risk türünün farklı belirleyicilere sahip olabileceği varsayımı dikkate alınmış ve hedeflere özgü modeller oluşturulmuştur.

Bütünleşik Risk Skoru

Makine öğrenmesi modelleri tarafından üretilen risk tahminlerinin yöneticiler tarafından daha kolay yorumlanabilmesi amacıyla bütünleşik risk skoru yaklaşımı geliştirilmiştir. Bu yaklaşım farklı veri kaynaklarından elde edilen sinyalleri tek bir skor altında birleştirmektedir.

Şekil 2.2'de gösterilen yapı doğrultusunda sistem üç farklı veri kaynağını kullanabilmektedir:

- Makine öğrenmesi risk tahminleri
- Nabız anketlerinden elde edilen risk göstergeleri
- 360 derece geribildirimlerden elde edilen NLP analiz sonuçları

Üç veri kaynağının da mevcut olduğu durumlarda bütünleşik risk skoru aşağıdaki şekilde hesaplanmaktadır:

$$BRS = 0.60 \times ML_{risk} + 0.20 \times ARS + 0.20 \times NLP_{flight}$$

NLP verisinin bulunmadığı durumlarda ağırlıklar dinamik olarak yeniden dağıtılmaktadır:

$$BRS = 0.70 \times ML_{risk} + 0.30 \times ARS$$

Makine öğrenmesi risk bileşeni ise dört farklı hedef için üretilen risk puanlarının ağırlıklı ortalamasından oluşmaktadır:

$$ML_{risk} = 0.35PD + 0.30IR + 0.25YR + 0.10TK$$

Burada;

- PD: Performans Düşüşü Riski
- İR: İstifa Riski
- YR: Yüksek Risk Tahmini
- TK: Tükenmişlik Riski

olarak tanımlanmaktadır.

Ağırlıkların belirlenmesinde performans yönetimi açısından kritik kabul edilen risk türlerine daha yüksek önem verilmiştir. Özellikle performans düşüşü ve istifa riski organizasyonel etkileri nedeniyle daha yüksek ağırlıklarla değerlendirilmiştir.

Hesaplanan bütünleşik risk skorları üç farklı seviyede sınıflandırılmaktadır:

- 0–29 : Güvenli
- 30–59 : Orta Risk
- 60–100 : Yüksek Risk

Bu sınıflandırma sayesinde yöneticilerin çok sayıda performans göstergesini incelemek yerine çalışan risk durumunu tek bir gösterge üzerinden değerlendirebilmesi amaçlanmıştır.

3.7 Veri Kümesi Hazırlığı

Makine öğrenmesi modellerinin eğitilebilmesi için yeterli hacimde, tutarlı ve etiketlenmiş veri kümelerine ihtiyaç duyulmaktadır. Ancak çalışan performansı, motivasyon düzeyi ve işten ayrılma riski gibi veriler kurumlar açısından hassas bilgi niteliği taşıdığından gerçek kurumsal veri setlerine erişim çoğu zaman mümkün olmamaktadır. Bu nedenle araştırma kapsamında model geliştirme ve sistem doğrulama süreçlerinde kullanılmak üzere gerçekçi sentetik veri kümeleri oluşturulmuştur.

Sentetik veri üretim sürecinde amaç tamamen rastgele veri üretmek değil, gerçek kurumsal ortamlarda gözlemlenebilecek davranış örüntülerini ve değişkenler arasındaki ilişkileri yansıtan veri setleri oluşturmaktır. Bu doğrultuda her çalışan için bireysel performans profili tanımlanmış ve çalışanların zaman içerisindeki davranışlarını temsil eden parametreler kullanılmıştır.

Veri üretiminde performans, kalite, iş yükü, motivasyon ve ekip etkileşimi göstergeleri arasında literatürde raporlanan ilişkiler dikkate alınmıştır. Örneğin iş yükü seviyesindeki artışın hata yoğunluğunu artırması, motivasyon skorlarını düşürmesi ve tükenmişlik riskini yükseltmesi; yüksek motivasyon seviyesinin ise görev tamamlama oranı ve performans

göstergeleri üzerinde olumlu etki oluşturmaları sağlanmıştır. Böylece oluşturulan veri kümesinde değişkenler arasında gerçek hayata benzer korelasyon yapılarının ortaya çıkması amaçlanmıştır.

Verilerin haftalık zaman serisi yapısını temsil edebilmesi için her çalışan için 52 haftalık performans geçmişi oluşturulmuştur. Böylece çalışan davranışlarının zaman içerisindeki değişimi modellenilebilmiş ve lag, rolling ve trend tabanlı özellik mühendisliği işlemlerinin uygulanabilmesi mümkün hâle gelmiştir.

Makine öğrenmesi modellerinde kullanılan hedef değişkenler ikili sınıflandırma problemi olarak tasarlanmıştır. Performans düşüşü, tükenmişlik, istifa riski ve yüksek risk durumu olmak üzere dört farklı hedef değişken oluşturulmuştur. Etiket üretim sürecinde sınıf dağılımlarının aşırı dengesiz hâle gelmesini önlemek amacıyla Bernoulli dağılımına dayalı kontrollü örnekleme yaklaşımı kullanılmıştır. Böylece hem pozitif hem de negatif sınıfların model tarafından yeterli düzeyde öğrenilebilmesi hedeflenmiştir.

Satış departmanı veri kümesinde hedef değişkenlerin dağılımları sırasıyla performans düşüşü için %32, tükenmişlik riski için %40, istifa riski için %30 ve yüksek risk durumu için %35 olarak yapılandırılmıştır. Bu oranlar, sınıf dengesizliği problemini azaltırken gerçek kurumsal ortamlarda karşılaşılabilecek risk seviyelerini temsil edecek şekilde belirlenmiştir. Araştırma kapsamında oluşturulan nihai veri kümeleri Çizelge 3.6'da özetlenmiştir.

Departman	Çalışan Sayısı	Hafta Sayısı	Toplam Kayıt
Yazılım	31	52	1.560
Satış	31	52	1.612
Toplam	62	52	3.172

Çizelge 3.6. Veri Kümesi Özeti

Oluşturulan veri kümeleri, sistemin geliştirilmesi, özellik mühendisliği süreçlerinin doğrulanması ve makine öğrenmesi modellerinin eğitilmesi amacıyla kullanılmıştır. Bununla birlikte sentetik verilerin gerçek kurumsal davranışları tam olarak temsil edemeyeceği göz

önünde bulundurulmalı ve elde edilen model performansları gerçek kurum verileri üzerinde gerçekleştirilecek çalışmalarla yeniden doğrulanmalıdır.

3.8 Deneysel Tasarım ve Değerlendirme Metodolojisi

Makine öğrenmesi projelerinde elde edilen performans sonuçlarının güvenilir biçimde yorumlanabilmesi için model eğitim ve değerlendirme sürecinin sistematik olarak tasarlanması gerekmektedir. Özellikle zaman bağımlı veriler üzerinde gerçekleştirilen çalışmalarda değerlendirme metodolojisinin yanlış seçilmesi durumunda model performansı gerçekte olduğundan daha yüksek görünebilmektedir. Bu nedenle çalışma kapsamında model geliştirme süreci, veri sızıntısını önleyecek ve gerçek kullanım koşullarını temsil edecek şekilde yapılandırılmıştır.

Bu araştırmada hem yazılım hem de satış departmanları için oluşturulan veri kümeleri üzerinde dört farklı hedef değişken için ayrı ikili sınıflandırma modelleri eğitilmiştir. Her hedef değişken bağımsız bir problem olarak ele alınmış ve performans düşüşü, tükenmişlik riski, istifa riski ve yüksek risk durumu için ayrı modeller oluşturulmuştur.

3.8.1 Eğitim ve Test Verilerinin Ayrılması

Makine öğrenmesi uygulamalarında yaygın olarak kullanılan rastgele eğitim-test ayrımı yaklaşımı zaman serisi verilerinde yanıltıcı sonuçlar üretebilmektedir. Rastgele bölme yapıldığında geleceğe ait kayıtlar eğitim kümesine sızabilmekte ve modelin gerçekte sahip olmadığı bilgiyle öğrenmesine neden olabilmektedir. Bu durum literatürde veri sızıntısı (data leakage) olarak adlandırılmaktadır [22].

Bu problemi önlemek amacıyla çalışma kapsamında zaman sıralamasına duyarlı (temporal split) eğitim-test ayrımı uygulanmıştır. Her çalışanın performans geçmişi kronolojik sırada değerlendirilmiş ve en güncel dönemler test kümesi olarak ayrılmıştır. Böylece modeller yalnızca geçmiş verileri kullanarak gelecekteki performansı tahmin edecek şekilde eğitilmiştir.

Bu yaklaşım, sistemin gerçek kullanım senaryosunu daha doğru temsil etmekte ve model performansının daha güvenilir biçimde ölçülmesine olanak sağlamaktadır.

3.8.2 Değerlendirme Ölçütleri

Model performansının değerlendirilmesinde tek bir ölçüt kullanılması çoğu zaman yeterli değildir. Özellikle sınıf dağılımlarının tam dengeli olmadığı veri kümelerinde doğruluk (accuracy) değeri tek başına yanıltıcı olabilmektedir. Bu nedenle çalışma kapsamında birden fazla performans ölçütü birlikte kullanılmıştır.

Doğruluk (Accuracy)

Doğruluk, model tarafından doğru sınıflandırılan gözlem sayısının toplam gözlem sayısına oranını ifade etmektedir.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Bu ölçüt modelin genel başarısını göstermektedir.

Kesinlik (Precision)

Kesinlik değeri, model tarafından pozitif olarak sınıflandırılan örneklerin ne kadarının gerçekten pozitif olduğunu göstermektedir.

$$\text{Precision} = \frac{TP}{TP + FP}$$

Özellikle yanlış alarm maliyetinin yüksek olduğu durumlarda önemli bir göstergedir.

Duyarlılık (Recall)

Duyarlılık, gerçek pozitif örneklerin ne kadarının model tarafından yakalanabildiğini ifade etmektedir.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Risk tahmini uygulamalarında yüksek recall değeri önem taşımaktadır çünkü riskli çalışanların gözden kaçırılması istenmemektedir.

F1 Skoru

F1 skoru, precision ve recall değerlerinin harmonik ortalamasıdır.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Bu çalışmada model karşılaştırmalarında temel değerlendirme ölçütü olarak F1 skoru kullanılmıştır. Bunun nedeni F1 skorunun hem yanlış pozitif hem de yanlış negatif sınıflandırmaları birlikte dikkate almasıdır.

Makro F1 ve Ağırlıklı F1

Çalışmada Macro F1 ve Weighted F1 değerleri de raporlanmıştır.

Makro F1, tüm sınıflara eşit önem vermekte ve her sınıf için hesaplanan F1 değerlerinin aritmetik ortalamasını almaktadır.

Ağırlıklı F1 ise sınıfların veri kümesindeki dağılımlarını dikkate almaktadır.

Bu nedenle Macro F1 sınıf dengesi açısından, Weighted F1 ise gerçek veri dağılımı açısından model başarısını değerlendirmeye yardımcı olmaktadır.

3.8.3 Model Seçim Kriterleri

Modeller karşılaştırılırken yalnızca doğruluk değerleri dikkate alınmamıştır. Model seçim sürecinde aşağıdaki kriterler birlikte değerlendirilmiştir:

- Ağırlıklı F1 skoru
- Makro F1 skoru
- Genelleme performansı
- Hesaplama maliyeti
- Yorumlanabilirlik
- Eğitim süresi

Bu kriterler doğrultusunda yazılım departmanında Random Forest algoritması, satış departmanında ise Stacking Tabanlı Ensemble Mimarisi tercih edilmiştir.

3.8.4 Deneysel Ortam

Tüm modeller Python programlama dili kullanılarak geliştirilmiş ve scikit-learn ekosistemi üzerinde eğitilmiştir. Satış departmanında kullanılan stacking mimarisinde LightGBM, XGBoost ve Random Forest temel öğrencileri; Lojistik Regresyon ise meta öğrenci olarak kullanılmıştır.

Model eğitimleri departman bazında bağımsız olarak gerçekleştirilmiş ve her hedef değişken için ayrı model artefaktları oluşturulmuştur. Eğitim sonrasında elde edilen modeller sistem içerisine kaydedilmiş ve risk tahmin süreçlerinde yeniden kullanılabilir hâle getirilmiştir.

4.BULGULAR

4.1 Makine Öğrenmesi Model Performansı

Her iki departman için dört hedef (Performans Düşüşü, Tükenmişlik, İstifa Riski, Yüksek Risk) ayrı ikili sınıflandırma modeli olarak eğitilmiştir. Test kümesi üzerinde elde edilen performans metrikleri aşağıdaki çizelgelerde sunulmaktadır.

Hedef	Doğruluk (%)	Makro F1 (%)	Ağırlıklı F1 (%)	Model
Performans Düşüşü	100,0	100,0	100,0	Stacking
Tükenmişlik	98,1	97,9	98,1	Stacking
İstifa Riski	100,0	100,0	100,0	Stacking
Yüksek Risk	98,1	98,3	98,2	Stacking

Çizelge 4.1. Satış Departmanı ML Model Performansı (Stacking Ensemble)

Hedef	Doğruluk (%)	Makro F1 (%)	Ağırlıklı F1 (%)	Model
Performans Düşüşü	79,2	74,8	79,0	RF
Tükenmişlik	76,4	73,1	76,3	RF
İstifa Riski	81,3	77,2	80,9	RF
Yüksek Risk	77,8	75,4	77,6	RF

Çizelge 4.2. Yazılım Departmanı ML Model Performansı (Random Forest)

Satış modelinde gözlemlenen yüksek F1 skorları (%98,9–%100), bireysel çalışan profilleri üzerinden üretilen sentetik veride beklenen bir sonuçtur; bu durum modelin gerçek dünya koşullarındaki genellenebilirliğine ilişkin sınırlı bilgi vermektedir. Yazılım modeli için elde edilen %76–%81 aralığındaki skorlar ise daha dengeli bir öğrenme ortamını yansıtmaktadır. Toplu tahmin işlevinde gerçekleştirilen vektörel işlem optimizasyonu, çağrı sürelerini bireysel döngü yaklaşımına kıyasla 59 kat kısaltmıştır (43.562 ms → 736 ms).

4.2 Geliştirilen Sistem Modülleri

Bu bölümde KUTUP sistemi kapsamında geliştirilen temel modüller ve bu modüllerin performans yönetimi süreçlerine sağladığı katkılar açıklanmaktadır. Sistem; rol tabanlı erişim kontrolü yaklaşımı doğrultusunda tasarlanmış olup sistem yöneticisi, departman yöneticisi ve çalışan olmak üzere üç farklı kullanıcı grubuna hizmet vermektedir. Her kullanıcı grubu yalnızca kendi görev ve sorumluluk alanlarıyla ilişkili verilere erişebilmekte ve sistem işlevlerini bu kapsamda kullanabilmektedir.

4.2.1 Rol Tabanlı Giriş ve Yönlendirme

Sistem içerisinde farklı kullanıcı gruplarının ihtiyaç duyduğu bilgi ve işlevler birbirinden farklı olduğundan rol tabanlı erişim yaklaşımı benimsenmiştir. Kullanıcılar sisteme giriş yaptıktan sonra sahip oldukları rol ve departman bilgisine göre yetkilendirilmekte ve ilgili çalışma alanlarına yönlendirilmektedir. Bu yaklaşım sayesinde hem güvenlik gereksinimleri karşılanmakta hem de kullanıcıların yalnızca yetkili oldukları verilere erişebilmeleri sağlanmaktadır.

Kimlik doğrulama süreci JSON Web Token (JWT) mekanizması ile gerçekleştirilmektedir. Başarılı giriş sonrasında kullanıcı rolü ve departman bilgisi belirteç içerisine eklenmekte ve sistem içerisindeki erişim kararları bu bilgiler doğrultusunda verilmektedir. Çizelge 4.3'te sistemde tanımlanan kullanıcı rolleri ve yönlendirildikleri temel çalışma alanları gösterilmektedir.

Kullanıcı	Rol	Örnek Kullanıcı	Hedef Sayfa
Sistem Yöneticisi	<i>admin</i>	admin@propel.com	<i>/admin</i>
Yazılım Yöneticisi	<i>dept_manager</i>	manager.yazilim@propel.com	<i>/manager</i>
Satış Yöneticisi	<i>dept_manager</i>	manager.satis@propel.com	<i>/manager/sales-kpi-analysis</i>
Yazılım Çalışanı	<i>employee</i>	developer1@propel.com	<i>/employee</i>
Satış Çalışanı	<i>employee</i>	satis.employee@propel.com	<i>/employee/sales</i>

Çizelge 4.3. Rol Tabanlı Giriş ve Yönlendirme Matrisi

Bu yapı sayesinde sistem yöneticileri tüm organizasyona ilişkin verilere erişebilirken, departman yöneticileri yalnızca sorumlu oldukları ekiplerin performans ve risk analizlerini görüntüleyebilmekte, çalışanlar ise kendi bireysel performans bilgilerine erişebilmektedir.

4.2.2 Admin Paneli

Admin paneli, sistemin genel durumunun izlenmesi ve yönetilmesi amacıyla geliştirilmiştir. Bu modül üzerinden kullanıcı yönetimi, veri yönetimi, performans analizleri ve sistem genelindeki risk göstergeleri takip edilebilmektedir. Böylece organizasyon düzeyindeki performans görünümü tek bir arayüz üzerinden değerlendirilebilmektedir.

Panel içerisinde Genel Bakış, Çalışan Yönetimi, Veri Yönetimi, Yapay Zekâ İçgörüler ve Anket Sonuçları olmak üzere beş temel modül bulunmaktadır. Genel Bakış ekranı, sistem genelindeki performans göstergelerini, departman bazlı risk dağılımlarını ve yüksek risk grubunda yer alan çalışanları özetleyen bir kontrol paneli işlevi görmektedir.

Çalışan Yönetimi modülü, sistemde kayıtlı çalışanların performans ve risk durumlarının merkezi olarak izlenebilmesini sağlamaktadır. Bu modülde makine öğrenmesi tahminleri, nabız anketleri ve doğal dil işleme analizlerinden elde edilen çıktılar bütünleşik risk skoru altında birleştirilmektedir. Böylece farklı veri kaynaklarından elde edilen göstergeler tek bir karar destek mekanizması içerisinde değerlendirilebilmektedir.

Yüksek risk grubunda bulunan çalışanlar için sistem tarafından önceliklendirilmiş aksiyon önerileri sunulmaktadır. Bu öneriler performans düşüşü, tükenmişlik veya işten ayrılma riski gibi faktörlere bağlı olarak yöneticilere müdahale seçenekleri sağlamaktadır. Benzer şekilde düşük risk grubunda yer alan çalışanlar için ödüllendirme ve motivasyon artırıcı öneriler oluşturulmaktadır. Bu yaklaşım performans yönetiminin yalnızca problem tespiti değil, aynı zamanda çalışan bağlılığını artırmaya yönelik uygulamaları da desteklemesini amaçlamaktadır.

4.2.3 Yönetici Paneli

Yönetici paneli, departman bazlı performans değerlendirmesi ve risk analizlerinin gerçekleştirilmesi amacıyla tasarlanmıştır. Departman yöneticileri yalnızca sorumlu oldukları ekiplerin verilerine erişebilmekte ve analiz süreçlerini bu kapsamda yürütebilmektedir. Böylece performans yönetimi süreçlerinde daha odaklı ve bağlama duyarlı karar desteği sağlanmaktadır.

Yazılım geliştirme departmanına yönelik yönetici ekranında performans düşüşü, tükenmişlik riski, işten ayrılma riski ve yüksek risk durumu için geliştirilen makine öğrenmesi modellerinin eğitilmesi, değerlendirilmesi ve toplu tahmin süreçleri gerçekleştirilebilmektedir.

Sistem tarafından üretilen risk skorları renk tabanlı görselleştirme yöntemleriyle sunularak yöneticilerin kritik durumları daha hızlı tespit edebilmesi amaçlanmıştır.

Satış departmanına yönelik yönetici ekranında ise takım bazlı performans analizi ve risk değerlendirmesi gerçekleştirilmektedir. Departman ve takım seviyesinde sunulan analizler sayesinde yöneticiler ekip performanslarını karşılaştırabilmekte, zaman içerisindeki değişimleri takip edebilmekte ve bireysel çalışan düzeyindeki risk göstergelerini inceleyebilmektedir.

Makine öğrenmesi modellerinden elde edilen sonuçlar Google Gemini entegrasyonu aracılığıyla doğal dilde yorumlanabilmekte ve yöneticilere daha anlaşılır raporlar sunulabilmektedir. Böylece teknik model çıktılarının karar verme süreçlerinde kullanılabilirliği artırılmaktadır.

4.2.4 Çalışan Paneli

Çalışan paneli, bireysel performansın izlenmesi ve çalışanların kendi gelişim süreçlerine ilişkin farkındalık kazanabilmeleri amacıyla geliştirilmiştir. Kullanıcılar bu panel aracılığıyla performans göstergelerini, risk değerlendirmelerini ve sistem tarafından oluşturulan önerileri görüntüleyebilmektedir.

Satış departmanı çalışanları için geliştirilen panelde bireysel performans verileri, makine öğrenmesi tabanlı risk tahminleri, yapay zekâ destekli koçluk önerileri ve nabız anketleri tek bir çalışma alanında bir araya getirilmektedir. Böylece çalışanların kendi performans durumlarını daha bütüncül biçimde değerlendirebilmeleri amaçlanmaktadır.

Yazılım geliştirme departmanı çalışanları için oluşturulan panelde ise görev tamamlama oranı, zaman yönetimi göstergeleri ve hata yoğunluğu gibi departmana özgü performans metrikleri sunulmaktadır. Ayrıca sistem tarafından üretilen öneriler aracılığıyla çalışanların gelişim alanlarını belirlemeleri desteklenmektedir.

Bu yaklaşım sayesinde performans yönetimi süreci yalnızca yöneticiler tarafından yürütülen bir faaliyet olmaktan çıkarılarak çalışan katılımını da destekleyen bir yapıya dönüştürülmektedir.

4.2.5 LLM Destekli Raporlama

KUTUP sisteminin dikkat çeken bileşenlerinden biri büyük dil modeli (LLM) destekli raporlama mekanizmasıdır. Sistem içerisinde Google Gemini API entegrasyonu kullanılarak makine öğrenmesi modelleri ve performans analizlerinden elde edilen sonuçlar doğal dilde açıklanabilmektedir.

LLM destekli raporlama mekanizması; departman özetlerinin oluşturulması, çalışan bazlı risk raporlarının hazırlanması, nabız anketlerinin yorumlanması ve yapay zekâ destekli koçluk önerilerinin üretilmesi gibi farklı iş süreçlerinde kullanılmaktadır. Böylece kullanıcıların teknik analiz sonuçlarını daha kolay yorumlayabilmeleri sağlanmaktadır.

Kurumsal sistemlerde dış servis bağımlılığının oluşturabileceği erişilebilirlik risklerini azaltmak amacıyla sistemde yedek bir raporlama mekanizması da geliştirilmiştir. Büyük dil modeli servisinin geçici olarak kullanılamadığı durumlarda önceden tanımlanmış kural tabanlı şablonlar devreye girerek temel raporlama işlevlerinin devam etmesini sağlamaktadır. Bu yaklaşım sistem sürekliliğine katkı sunmakta ve raporlama hizmetinin kesintisiz biçimde sürdürülebilmesine olanak tanımaktadır.

Genel olarak değerlendirildiğinde KUTUP' un sistem mimarisi; yönetici, çalışan ve sistem yöneticisi rollerinin ihtiyaçlarını karşılayacak şekilde tasarlanmıştır. Rol tabanlı erişim kontrolü, makine öğrenmesi tabanlı analizler, doğal dil işleme bileşenleri ve büyük dil modeli destekli raporlama mekanizmaları aynı platform içerisinde bütünleştirilmiştir. Böylece performans yönetimi süreçlerinin yalnızca veri toplama ve raporlama faaliyetlerinden ibaret kalmayıp veri odaklı karar desteği sağlayan bütünsel bir yapıya dönüştürülmesi amaçlanmıştır.


4.3 Teknik Bulgular

4.3.1 Performans Optimizasyonu Sonuçları

KUTUP sisteminin geliştirilmesi sırasında yalnızca tahmin doğruluğunun artırılması değil, aynı zamanda sistem performansının iyileştirilmesi de hedeflenmiştir. Özellikle çok sayıda çalışan için eş zamanlı risk analizi gerçekleştirilen senaryolarda tahmin süresinin kullanıcı deneyimi üzerinde doğrudan etkili olduğu görülmüştür.

İlk uygulamada çalışanlar için tahmin işlemleri döngü (for-loop) yapısı kullanılarak bireysel olarak gerçekleştirilmiştir. Ancak bu yaklaşım veri hacmi arttıkça önemli performans kayıplarına neden olmuştur. Bu sorunu gidermek amacıyla tahmin süreci yeniden tasarlanmış ve bireysel çağrılar yerine DataFrame tabanlı toplu tahmin yaklaşımı uygulanmıştır.

Şekil 4.1'de görüldüğü üzere gerçekleştirilen optimizasyon sonucunda toplam işlem süresi 43.562 ms'den 736 ms'ye düşürülmüştür. Böylece sistem yaklaşık 59 kat daha hızlı çalışır hâle gelmiştir.



Şekil 4.1. Toplu Tahmin Optimizasyonu Sonuçları


Bu sonuç, geliştirilen mimarinin yalnızca akademik bir prototip değil, aynı zamanda gerçek kullanım senaryolarında uygulanabilecek ölçeklenebilir bir yapı sunduğunu göstermektedir. Özellikle yönetici panellerinde yüzlerce çalışanın aynı anda analiz edilmesi gereken durumlarda bu optimizasyon kritik önem taşımaktadır.

4.3.2 Özellik Mühendisliği ve Değişken Önemi Analizi

Makine öğrenmesi modellerinin performansını etkileyen en önemli unsurlardan biri kullanılan özelliklerin niteliğidir. Bu nedenle çalışma kapsamında yalnızca anlık KPI değerleri değil, aynı zamanda zaman içerisindeki değişimi temsil eden türetilmiş özellikler de modele dahil edilmiştir.

Özellik önem analizleri incelendiğinde, zaman serisi tabanlı değişkenlerin model kararları üzerinde önemli etkiler oluşturduğu görülmüştür. Şekil 4.2'de satış departmanı için elde edilen örnek değişken önem sıralaması sunulmaktadır.

4.2 – Makine Öğrenmesi Satış Modeli Özellik Önem Sıralaması (Feature Importance)



Şekil 4.2. Makine Öğrenmesi Satış Modeli Özellik Önem Sıralaması

Grafik incelendiğinde satış hedef gerçekleştirme oranı (SHGO) ve haftalık gelir eğilimi (weekly_revenue_trend_4) değişkenlerinin en yüksek katkıya sahip olduğu görülmektedir. Bunun yanında lead dönüşüm oranı ve hareketli ortalama tabanlı gelir göstergeleri de model performansında önemli rol oynamaktadır.

Dikkat çekici bulgulardan biri, trend_4 ve rolling_4 gibi zaman serisi türevlerinin üst sıralarda yer almasıdır. Bu durum çalışan performansının yalnızca mevcut seviyesinin değil, zaman içerisindeki değişim yönünün de tahmin başarısında belirleyici olduğunu göstermektedir. Elde edilen sonuçlar Cheng tarafından raporlanan bulgularla uyumlu olup, zaman serisi tabanlı özellik mühendisliğinin performans analitiği çalışmalarındaki önemini desteklemektedir [9].

4.3.3 Sistem Mimarisi ve Genişletilebilirlik Bulguları

Geliştirme sürecinde elde edilen bir diğer önemli bulgu, modüler yazılım mimarisinin sürdürülebilirlik ve genişletilebilirlik açısından sağladığı avantajlardır. Sistem içerisinde her departman için bağımsız FeatureBuilder, Trainer, PredictionService, ArtifactStore ve ExplanationBuilder bileşenleri geliştirilmiştir.

Bu yapı sayesinde yeni bir departmanın sisteme eklenmesi durumunda mevcut kod tabanında kapsamlı değişiklikler yapılmasına ihtiyaç duyulmamaktadır. Yalnızca ilgili

departmana özgü KPI tanımlarının ve iş kurallarının eklenmesi yeterli olmaktadır. Bu durum sistemin bakım maliyetini azaltmakta ve gelecekteki geliřtirmeleri kolaylařtırmaktadır.

Veri iřleme sürecinde ayrıca farklı kaynaklardan gelen veri kümelerindeki kolon isimlendirme farklılıklarını gidermek amacıyla otomatik kolon normalleřtirme mekanizması geliřtirilmiřtir. Bu mekanizma sayesinde gerek veri kümelerinde sıklıkla karřılařılan isimlendirme tutarsızlıklarının sistem üzerinde oluřturabileceėi hatalar azaltılmıřtır.

4.3.4 Veri Üretimi ve Veri Seti Özeti

alıřma kapsamında makine öğrenmesi modellerinin eğitilmesi ve sistemin test edilmesi amacıyla kapsamlı bir veri üretim süreci gerekleřtirilmiřtir. Bu süreç sonucunda iki departmanı kapsayan toplam 45 KPI tanımı oluřturulmuř ve 62 alıřan için 52 haftalık zaman serisi verisi üretilmiřtir.

Ayrıca doėal dil iřleme bileřeninin eğitimi ve test edilmesi amacıyla 1.883 adet 360 derece geribildirim metni ile 558 adet NLP profili oluřturulmuřtur. Üretilen veri setleri performans yönetimi, risk analizi ve doėal dil iřleme bileřenlerinin bütünüleřik olarak test edilmesine olanak saėlamıřtır.

Genel olarak deėerlendirildiėinde teknik bulgular, geliřtirilen sistemin yalnızca makine öğrenmesi performansı açısından deėil; öleklenebilirlik, performans optimizasyonu, veri iřleme kabiliyeti ve geniřletilebilir mimari yapısı açısından da bařarılı sonuçlar ortaya koyduėunu göstermektedir.

5.SONUÇ VE ÖNERİLER

5.1 Projenin Değerlendirilmesi

Bu çalışma kapsamında geliştirilen KUTUP sistemi, performans yönetimi, risk analitiği ve karar destek süreçlerini bütünsel bir yapıda ele alan web tabanlı bir platform olarak tasarlanmış ve gerçekleştirilmiştir. Çalışmanın temel amacı, çalışan performansının yalnızca geçmiş veriler üzerinden değerlendirilmesi yerine, veri analitiği ve makine öğrenmesi yöntemleri kullanılarak gelecekte ortaya çıkabilecek risklerin öngörülmesine katkı sağlayacak bir sistem geliştirmektir.

Bu amaç doğrultusunda yazılım geliştirme ve satış departmanlarına yönelik performans göstergeleri belirlenmiş, literatür destekli KPI setleri oluşturulmuş ve bu göstergeler kullanarak performans analizi gerçekleştirilmiştir. Sistem içerisinde performans düşüşü, tükenmişlik riski, işten ayrılma riski ve yüksek risk durumu olmak üzere dört farklı hedef değişken için makine öğrenmesi modelleri geliştirilmiştir. Ayrıca çalışanlardan elde edilen 360 derece geribildirimler doğal dil işleme teknikleri kullanılarak analiz edilmiş ve elde edilen çıktılar risk değerlendirme sürecine dahil edilmiştir.

Araştırma bulguları, çalışan performansının değerlendirilmesinde yalnızca anlık performans göstergelerinin kullanılmasının yeterli olmadığını göstermektedir. KPI değerlerinden türetilen gecikmeli değişkenler, hareketli ortalamalar ve trend göstergeleri gibi zaman serisi özelliklerinin performans tahminlerinde önemli katkılar sağladığı gözlemlenmiştir. Bu durum, literatürde zaman serisi tabanlı performans modelleme çalışmalarında elde edilen bulgularla uyumlu sonuçlar ortaya koymaktadır.

Çalışmanın bir diğer önemli sonucu, farklı veri kaynaklarının bütünsel biçimde kullanılmasının karar destek kapasitesini artırmasıdır. KPI verileri, çalışan geri bildirimleri ve nabız anketlerinden elde edilen göstergelerin birlikte değerlendirilmesi sayesinde performans ve risk analizleri daha kapsamlı bir yapıya kavuşmuştur. Böylece yalnızca mevcut durumun değerlendirilmesi değil, gelecekte ortaya çıkabilecek risklerin erken aşamada belirlenmesi de mümkün hale gelmiştir.

Sistemin teknik açıdan değerlendirilmesi sonucunda modüler mimari yapısının yeni departmanlara uyarlanabilecek esneklikte olduğu görülmüştür. Ayrıca Docker Compose tabanlı

dağıtım yapısı, JWT tabanlı kimlik doğrulama mekanizması ve rol tabanlı erişim kontrolü sayesinde sistemin kurumsal kullanıma uygun bir altyapı sunduğu değerlendirilmiştir.

Genel olarak değerlendirildiğinde KUTUP, performans yönetimi, öngörücü analitik, doğal dil işleme ve büyük dil modeli destekli raporlama bileşenlerini tek bir platform altında bir araya getirerek veri odaklı yönetim anlayışını destekleyen bütünlüklü bir karar destek sistemi ortaya koymuştur.

5.2 Özgün Değer ve Akademik Katkılar

Bu çalışmanın en önemli katkılarından biri, performans yönetimi süreçlerinde kullanılan farklı veri kaynaklarını bütünlüklü bir analitik çerçevede bir araya getirmesidir. Literatürde yer alan birçok çalışma yalnızca performans göstergelerine, çalışan bağlılığına veya işten ayrılma tahminine odaklanırken bu çalışmada performans verileri, çalışan geri bildirimleri ve nabız anketleri birlikte değerlendirilmiştir.

Çalışmanın ikinci önemli katkısı, departmana özgü KPI mimarisinin geliştirilmesidir. Yazılım geliştirme ve satış departmanları için oluşturulan performans göstergeleri ilgili alanların operasyonel gereksinimleri dikkate alınarak tasarlanmıştır. Bu yaklaşım, farklı iş süreçlerinin aynı performans ölçütleriyle değerlendirilmesinin oluşturabileceği sınırlılıkların azaltılmasına katkı sağlamaktadır.

Araştırmanın bir diğer katkısı ise zaman serisi tabanlı özellik mühendisliğinin performans tahmin süreçlerine dahil edilmesidir. KPI göstergelerinden elde edilen gecikmeli değişkenler, hareketli ortalamalar ve trend özellikleri kullanılarak çalışan performansındaki değişimlerin daha doğru temsil edilmesi amaçlanmıştır. Bu yaklaşım performans değerlendirme süreçlerinin yalnızca mevcut duruma değil, performans eğilimlerine de odaklanmasını sağlamaktadır.

Sistemin doğal dil işleme ve büyük dil modeli entegrasyonu da çalışmanın özgün yönlerinden biridir. Çalışan geri bildirimlerinden elde edilen metinlerin analiz edilmesi ve makine öğrenmesi çıktılarının doğal dilde yönetim raporlarına dönüştürülmesi, teknik sonuçların karar vericiler tarafından daha kolay yorumlanabilmesine katkı sağlamaktadır.

Sonuç olarak bu çalışma, performans yönetimi alanında yapay zekâ destekli karar destek sistemlerinin uygulanabilirliğini gösteren ve farklı analitik yaklaşımları bütünleştiren bir örnek çalışma niteliği taşımaktadır.

5.3 Sınırlılıklar

Bu çalışmada elde edilen sonuçlar değerlendirilirken bazı sınırlılıkların dikkate alınması gerekmektedir. Öncelikle sistemde kullanılan makine öğrenmesi modelleri sentetik veri setleri üzerinde eğitilmiş ve test edilmiştir. Sentetik veriler geliştirme ve deneysel doğrulama açısından önemli avantajlar sağlamakla birlikte, gerçek kurumsal ortamlarda karşılaşılabilecek veri çeşitliliğini ve davranışsal karmaşıklığı tam olarak yansıtamayabilmektedir. Bu nedenle model performanslarının gerçek kurum verileri üzerinde yeniden doğrulanması gerekmektedir.

Araştırmada kullanılan performans göstergeleri ve risk tanımları belirli varsayımlar çerçevesinde oluşturulmuştur. Tükenmişlik riski, performans düşüşü ve işten ayrılma riski gibi kavramlar farklı kurumlarda farklı biçimlerde yorumlanabilmektedir. Bu nedenle sistem tarafından üretilen çıktılar doğrudan karar mekanizması olarak değil, karar destek aracı olarak değerlendirilmelidir.

Ayrıca sistemin kullanıcı deneyimi ve operasyonel uygunluğu gerçek kurum çalışanları ve yöneticileriyle kapsamlı kullanıcı kabul testlerinden geçirilmemiştir. Gelecekte gerçekleştirilecek saha çalışmaları, sistemin kullanılabilirliği ve kurumsal kabul düzeyi hakkında daha güçlü bulgular elde edilmesine katkı sağlayacaktır.

5.4 Gelecek Çalışma Önerileri

Gelecekte gerçekleştirilecek çalışmalar kapsamında sistemin anonimleştirilmiş gerçek kurum verileri üzerinde test edilmesi ve doğrulanması önemli bir araştırma alanı olarak değerlendirilmektedir. Bu sayede geliştirilen modellerin genellenebilirliği daha sağlıklı biçimde ölçülebilecek ve farklı organizasyonlardaki performansı karşılaştırılabilecektir.

Bir diğer geliştirme alanı açıklanabilir yapay zekâ tekniklerinin sisteme entegre edilmesidir. Özellikle SHAP ve benzeri yöntemler kullanılarak model tahminlerinin hangi değişkenlerden ne ölçüde etkilendiğinin gösterilmesi, yöneticilerin sistem çıktılarının güvenilirliğini daha iyi değerlendirmesine katkı sağlayabilir.

Sistemin farklı departmanlar ve sektörler için genişletilmesi de gelecekteki çalışmalar açısından önemli bir fırsat sunmaktadır. İnsan kaynakları, pazarlama, müşteri hizmetleri veya üretim gibi farklı alanlara yönelik KPI setlerinin geliştirilmesi, sistemin kullanım alanını genişletebilir.

Son olarak federated learning, model izleme sistemleri ve otomatik yeniden eğitim mekanizmaları gibi gelişmiş yapay zekâ yaklaşımlarının sisteme entegre edilmesi, hem veri güvenliği hem de uzun dönemli model performansı açısından önemli katkılar sağlayabilir. Bu tür çalışmalar KUTUP'un kurumsal ölçekte uygulanabilirliğini ve sürdürülebilirliğini artıracı araştırma yönleri olarak değerlendirilmektedir.

- **Asenkron LLM İşlemleri:** FastAPI arka plan görevleri (BackgroundTasks) veya Celery kuyruk sistemi kullanılarak Gemini çağrılarını asenkron hale getirilmeli; sonuçlar WebSocket ya da polling aracılığıyla ön yüze iletilmelidir.
- **Test Suite:** app/tests/ dizinine %80 kapsam hedefiyle pytest tabanlı birim ve entegrasyon testleri eklenmelidir. ML servisleri, KPI hesaplamaları ve bütünleşik skor formülü öncelikli test hedefleri olmalıdır.
- **Model İzleme:** Eğitilen modelin F1 skoru belirli bir eşiğin altına düştüğünde otomatik yeniden eğitim tetikleyen bir izleme mekanizması geliştirilmelidir.
- **KVKK Uyumluluk Modülü:** Çalışan verilerinin saklama süreleri, erişim logları ve rıza yönetimi için KVKK uyumluluk özellikleri sisteme entegre edilmelidir.

KAYNAKLAR

- [1] Aguinis, H. (2019). Performance management (4th ed.). Chicago Business Press.
- [2] Armstrong, M., & Baron, A. (2005). Managing performance: Performance management in action. Chartered Institute of Personnel and Development.
- [3] Borgatti, S. P., & Halgin, D. S. (2011). On network theory. *Organization Science*, 22(5), 1168–1181. <https://doi.org/10.1287/orsc.1100.0641>
- [4] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- [5] Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., et al. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901.
- [6] Cappelli, P., & Tavis, A. (2016). The performance management revolution. *Harvard Business Review*, 94(10), 58–67.
- [7] Caruso, C. C. (2014). Negative impacts of shiftwork and long work hours. *Rehabilitation Nursing*, 39(1), 16–25. <https://doi.org/10.1002/rnj.107>
- [8] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. <https://doi.org/10.1145/2939672.2939785>
- [9] Cheng, B., Wang, M., Mourali, M., Bhattacharya, S., Shi, H., & Chen, L. (2022). Predicting employee turnover intentions using machine learning approaches. *International Journal of Environmental Research and Public Health*, 19(1), 553. <https://doi.org/10.3390/ijerph19010553>
- [10] Cohn, M. (2005). Agile estimating and planning. Prentice Hall.
- [11] Domingos, P. (2012). A few useful things to know about machine learning. *Communications of the ACM*, 55(10), 78–87. <https://doi.org/10.1145/2347736.2347755>
- [12] Fallucchi, F., Coladangelo, M., Giuliano, R., & De Luca, E. W. (2020). Predicting employee attrition using machine learning techniques. *Computers*, 9(4), 86. <https://doi.org/10.3390/computers9040086>
- [13] Fenton, N., & Bieman, J. (2014). Software metrics: A rigorous and practical approach (3rd ed.). CRC Press.

- [14] Fielding, R. T. (2000). Architectural styles and the design of network-based software architectures (Doctoral dissertation, University of California, Irvine). <https://www.ics.uci.edu/~fielding/pubs/dissertation/top.htm>
- [15] Gallup. (2023). State of the global workplace: 2023 report. Erişim tarihi: 04 Ağustos 2026, <https://www.gallup.com/workplace/349484/state-of-the-global-workplace.aspx>
- [16] Ingram, T. N., LaForge, R. W., Avila, R. A., Schwepker, C. H., & Williams, M. R. (2020). Sales management: Analysis and decision making (10th ed.). Routledge.
- [17] Jones, C. (2008). Applied software measurement: Global analysis of productivity and quality (3rd ed.). McGraw-Hill.
- [18] Jones, M. B., Bradley, J., & Sakimura, N. (2015). JSON web token (JWT) (RFC 7519). IETF. <https://doi.org/10.17487/RFC7519>
- [19] Jurafsky, D., & Martin, J. H. (2023). Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition (3rd ed., draft). Erişim tarihi: 04 Ağustos 2026, <https://web.stanford.edu/~jurafsky/slp3/>
- [20] Ke, G., R. S., & Norton, D. P. (1996). The balanced scorecard: Translating strategy into action. Harvard Business School Press.
- [21] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.
- [22] Kuhn, M., & Johnson, K. (2019). Feature engineering and selection: A practical approach for predictive models. CRC Press.
- [23] Levenson, A. (2018). Using workforce analytics to improve strategy execution. *Human Resource Management*, 57(3), 685–700. <https://doi.org/10.1002/hrm.21850>
- [24] Marler, J. H., & Boudreau, J. W. (2017). An evidence-based review of HR analytics. *The International Journal of Human Resource Management*, 28(1), 3–26. <https://doi.org/10.1080/09585192.2016.1244699>
- [25] Maslach, C., Schaufeli, W. B., & Leiter, M. P. (2001). Job burnout. *Annual Review of Psychology*, 52, 397–422. <https://doi.org/10.1146/annurev.psych.52.1.397>
- [26] Mohammad, S. M. (2022). Ethics sheet for automatic emotion recognition and sentiment analysis. *Computational Linguistics*, 48(2), 239–278. https://doi.org/10.1162/coli_a_00433
- [27] Rockart, J. F. (1979). Chief executives define their own data needs. *Harvard Business Review*, 57(2), 81–93.

[28] Rubin, K. S. (2012). *Essential Scrum: A practical guide to the most popular agile process*. Addison-Wesley.


[29] Sandhu, R. S., Coyne, E. J., Feinstein, H. L., & Youman, C. E. (1996). Role-based access control models. *IEEE Computer*, 29(2), 38–47. <https://doi.org/10.1109/2.485845>

[30] Wolpert, D. H. (1992). Stacked generalization. *Neural Networks*, 5(2), 241–259. [https://doi.org/10.1016/S0893-6080\(05\)80023-1](https://doi.org/10.1016/S0893-6080(05)80023-1)

[31] Zoltners, A. A., Sinha, P., & Lorimer, S. E. (2008). Sales force effectiveness: A framework for researchers and practitioners. *Journal of Personal Selling & Sales Management*, 28(2), 115–131. <https://doi.org/10.2753/PSS0885-3134280201>


EKLER

EK A. Sistem Ekran Görüntüleri



Ek B — Veritabanı Şeması

Ek B — Veritabanı Şeması




Şekil B.1. KUTUP Platformu Eksiksiz Veritabanı Varlık-İlişki (ER) Diyagramı; Kutu renkleri mantıksal süreç gruplarını temsil etmekte olup, yazı boyutları okunabilirliği artıracak şekilde tasarlanmıştır. Bu şema tezin kodlanan nihai veri yapısını yansıtmaktadır.

Ek C — Örnek Veri Kümesi


A1	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z	AA
1	0.8238	0.7135	1.7507	0.6481	0.6818	0.4	0.625	218.9448	0.5748	0.3328	0.3606	5	0.98175	0	0.2808	67.3628	76.2141	0.7538	76.1544	0	0.7198	71.3425	0.1849	67.2402	Stahl	DuaK
2	0.7193	0.6878	1.4777	0.6769	0.6571	1	2.4	255.0622	0.5205	0.3272	0.4213	5	0.97933	0	0.1823	40.4474	81.196	0.5565	67.0994	0.1421	0.6902	69.4845	0.2635	58.4159	Stahl	Ota
3	0.6451	0.7197	2.5	0.7538	0.9474	1	2.7692	237.1669	0.5622	0.3486	0.4773	4	1.0978	0	0.2749	81.5262	79.8888	0.5345	80.8553	1.9505	0.8123	75.4884	0.1453	75.8288	Stahl	DuaK
4	0.6327	0.7066	0.8955	0.8951	1	0.6	1.15	0.0378	0.4857	0.3442	0.4805	4	1.01849	0	0.2648	79.0226	77.6752	0.6048	74.6838	0.6837	0.734	71.9623	0.207	68.5504	Stahl	DuaK
5	0.684	0.7462	0.5709	0.8449	0.8571	0.8	4	161.3283	0.5463	0.352	0.4525	5	1.10671	0	0.132	78.3443	78.8448	0.4878	77.441	2.5322	0.7181	71.9531	0.256	66.9479	Stahl	DuaK
6	0.6841	0.7138	1.738	0.8916	0.9592	0.8	3.2222	132.2891	0.4889	0.3131	0.4318	4	1.15181	0	0.2845	76.9813	76.8444	0.6329	76.9817	0.6104	0.6796	74.8694	0.2958	64.7779	Stahl	DuaK
7	0.7797	0.7197	0.5641	0.786	0.7828	1	3.6	65.3855	0.5418	0.3385	0.3778	4	1.18823	0	0.2441	86.6162	75.8534	0.5981	77.7555	0.9036	0.7086	78.3159	0.2707	78.9395	Stahl	DuaK
8	0.6468	0.7564	0.4084	0.8869	0.9333	0.8	4.6967	111.7008	0.4975	0.2516	0.5572	3	0.83709	0	0.2362	77.0608	75.7596	0.7962	77.9983	2.8254	0.8847	74.4821	0.342	63.3172	Stahl	Ota
9	0.7731	0.7085	0.9602	0.8488	1	0.8	2.5	288.805	0.5434	0.28	0.4215	5	1.12659	0	0.1807	77.7591	76.8657	0.5528	74.2273	1.79	0.5742	68.9031	0.2818	59.1643	Stahl	DuaK
10	0.7628	0.6503	0.8214	0.7952	0.7463	0.5	7	150.628	0.5686	0.396	0.4464	3	1.07437	0	0.2453	74.4526	75.145	0.5666	66.7645	0.9444	0.8508	69.307	0.3465	63.1102	Stahl	Ota
11	0.8148	0.7394	0.7287	0.8966	0.75	1	4.2	154.4007	0.4398	0.2895	0.5175	4	0.92031	0	0.2625	76.9813	76.8444	0.6329	76.9817	0.6104	0.6796	74.8694	0.2958	64.7779	Stahl	DuaK
12	0.7294	0.7323	1.5114	0.7135	0.8096	0.6	3.2222	132.2891	0.4889	0.3131	0.4318	4	1.15181	0	0.2845	76.9813	76.8444	0.6329	76.9817	0.6104	0.6796	74.8694	0.2958	64.7779	Stahl	DuaK
13	0.6867	0.8444	1.3952	0.8528	0.9208	1	4.2222	87.9612	0.5613	0.3206	0.4793	4	1.05057	0	0.2625	76.9813	76.8444	0.6329	76.9817	0.6104	0.6796	74.8694	0.2958	64.7779	Stahl	DuaK
14	0.7035	0.8044	0.8134	0.7188	0.8621	0.2	5	203.9091	0.4442	0.2944	0.5285	3	1.04423	0	0.1823	40.4474	81.196	0.5565	67.0994	0.1421	0.6902	69.4845	0.2635	58.4159	Stahl	Ota
15	0.6859	0.7051	1.2823	0.8784	0.6584	0.4	4.1425	127.9754	0.4895	0.2502	0.4759	4	1.04224	0	0.1823	40.4474	81.196	0.5565	67.0994	0.1421	0.6902	69.4845	0.2635	58.4159	Stahl	Ota
16	0.7443	0.6876	1.3654	0.7756	0.8847	0.2	4.8571	165.2514	0.5413	0.2488	0.5884	2	1.2558	0	0.1823	40.4474	81.196	0.5565	67.0994	0.1421	0.6902	69.4845	0.2635	58.4159	Stahl	Ota
17	0.6714	0.8253	0.6424	0.8005	0.85	0.6	5.6967	124.7848	0.4889	0.3131	0.4318	4	1.15181	0	0.2845	76.9813	76.8444	0.6329	76.9817	0.6104	0.6796	74.8694	0.2958	64.7779	Stahl	DuaK
18	0.6844	0.7461	0.4796	0.8508	0.8575	0.4	3.6967	198.7723	0.4251	0.3164	0.4717	4	1.14351	0	0.1823	40.4474	81.196	0.5565	67.0994	0.1421	0.6902	69.4845	0.2635	58.4159	Stahl	Ota
19	0.6892	0.7673	1.5625	0.7338	0.8487	0.2	4.625	87.9612	0.5613	0.3206	0.4793	4	1.05057	0	0.2625	76.9813	76.8444	0.6329	76.9817	0.6104	0.6796	74.8694	0.2958	64.7779	Stahl	DuaK
20	0.7862	0.7058	1.2807	0.8718	0.618	1	3.9057	125.7884	0.4257	0.3168	0.4223	3	1.05164	0	0.2533	62.3449	74.8694	0.4887	78.301	1.6176	0.6953	74.1997	0.2222	66.1159	Stahl	DuaK
21	0.6864	0.7565	1.2365	0.76	0.6471	1	5.3	171.5957	0.4328	0.2228	0.5655	3	1.03785	0	0.2541	85.7133	76.8553	0.6813	67.8995	2.4602	0.8886	76.3999	0.2994	61.521	Stahl	DuaK
22	0.7177	0.6889	0.6882	0.8889	0.88	1	5.5	117.6483	0.5647	0.387	0.4669	5	1.16534	0	0.189	82.0022	82.0711	0.5929	62.828	3.3524	0.7244	69.8991	0.2623	64.4791	Stahl	Ota
23	0.6828	0.7204	2.9602	0.7465	0.8718	0.4	3.4	165.0987	0.5101	0.3202	0.5165	3	1.13111	0	0.1944	72.12	79.8652	0.4435	73.4761	1.8586	0.9383	73.1728	0.198	58.9155	Stahl	DuaK
24	0.6849	0.7468	1.4475	0.8901	0.9512	1	3.3333	105.3484	0.5026	0.3448	0.5121	3	1.28073	0	0.189	80.613	79.453	0.4676	75.2889	2.8936	0.888	74.401	0.2781	75.8885	Stahl	DuaK
25	0.6716	0.7475	1.4032	0.8513	0.8867	0.4	1.8571	168.6885	0.2538	0.2215	0.5515	3	0.88849	0	0.2739	70.8028	76.9479	0.5838	76.9287	4.2339	0.8842	73.3504	0.2781	75.8885	Stahl	DuaK
26	0.6283	0.7786	0.6297	0.652	0.7037	0.8	2.375	204.7627	0.6884	0.3674	0.5396	3	1.14695	0	0.2458	68.8874	83.3312	0.5181	75.7486	1.0353	0.7762	71.9863	0.1857	73.9257	Stahl	DuaK

EK D — İlk Eğitimlerde Model Çıktıları

Yazılım Departmanı - Karmaşıklik Matrisleri (Random Forest)



Satis Departmanı - Karmaşıklik Matrisleri (Stacking: LGBM+XGB+RF -> LR)



ÖZGEÇMİŞ

Şerife Sena Özişçi

Computer Engineering Student (4th Year)

+90 5395172142

GitHub: <https://github.com/ddemi-ssena>
Istanbul/Bahçelievler

Computer Engineering student focused on AI-driven systems, computer vision, backend architecture, and real-time data processing. Experienced in developing full-stack and AI-integrated applications using Python, Java Spring Boot, FastAPI, and modern ML frameworks. Passionate about building scalable intelligent systems for real-world problems.

WORK EXPERIENCE

August 2025 -
September 2025

ETİYA- Software Development Intern

- Contributed to the development of Lantern, an intern management platform, improving mentor-student interaction and reporting features.
- Built and maintained a full-stack web application using Java (Spring Boot) and Vue.js (TypeScript).
- Developed an AI-powered REST API with Python (FastAPI) and integrated it into the existing system to analyze intern reports.
- Designed and optimized PostgreSQL database schemas, ensuring data consistency and persistence with JPA/Hibernate.
- Collaborated within an Agile/Scrum team, effectively using Git and GitHub for version control and workflow management.

July 2024 - July 2025

İSTUN - Teaching Assistant

- Assist students in C Programming, Object-Oriented Programming (OOP), and Algorithm Labs by answering questions and reviewing their assignments.
- Conduct grading and documentation of student projects and reports.
- Provide one-on-one support to students to reinforce fundamental programming concepts.
- Conducted data annotation using CVAT for a machine learning project.

July 2024 - September
2024

Makel Electric - Software Intern

- Learned and applied C# programming, focusing on Object-Oriented Programming (OOP) principles.
- Worked extensively on asynchronous programming to improve application performance.
- Designed and developed multiple projects, including:
 - A Weather App utilizing API integration for real-time data retrieval, a Flappy Bird game implementing physics-based mechanics, Rock-Paper-Scissors game with an interactive user interface.
- Enhanced problem-solving skills by conceptualizing and implementing creative project ideas.

EDUCATION

İSTANBUL SAĞLIK ve TEKNOLOJİ
ÜNİVERSİTESİ
2022-present
GPA - 3.32

Computer Engineering

Relevant Courses: Data Structures and Algorithms, Object-
Oriented Programming, Database Management, Artificial
Intelligence

Fusun Yönder Anatolian High School
2018-2022
OBP-92

PROJECTS

Real-Time Hand & Object-Based Threat Detection System

Python • YOLOv8 • MediaPipe • Computer Vision

- Developed a real-time threat detection system using YOLOv8 and MediaPipe Hands to analyze dangerous hand-object interactions.
- Trained custom object detection models for non-standard threats such as hammers and improvised tools.
- Implemented automated evidence recording with asynchronous video capture and snapshot generation upon threat detection.
- Designed a modular and scalable architecture by separating detection, tracking, and analysis components.

AI-Powered Intern Analytics & Evaluation Platform

Spring Boot • FastAPI • Vue.js • PostgreSQL • NLP

- Developed a full-stack AI-powered platform for analyzing intern reports and mentor evaluations.
- Integrated a Python FastAPI AI service with a Java Spring Boot backend using REST APIs.
- Implemented NLP-based analysis using Hugging Face Transformers and spaCy for sentiment, keyword, and risk analysis.
- Built responsive mentor and intern dashboards with Vue.js and TypeScript.

KUTUP| AI-Powered HR Analytics & Performance Management System (Ongoing)

FastAPI • Vue.js • PostgreSQL • Docker

- Developing an AI-supported HR analytics platform for employee performance and organizational monitoring.
- Integrating predictive analytics models to forecast burnout risks, KPI deviations, and motivation trends.
- Designing a secure RBAC architecture with JWT authentication for role-based access management.
- Containerizing the system using Docker and Docker Compose for scalable deployment.

Time Booth AI | Generative AI Mobile Experience

React Native • Gemini API • ElevenLabs • FaLai

- Developed an AI-powered mobile photobooth application using React Native and Generative AI technologies.
- Integrated Google Gemini and ElevenLabs APIs to create dynamic voice-guided photography interactions.
- Implemented image-to-image generation workflows to transform user portraits into different artistic eras and styles.
- Automated digital photo delivery using Resend API for seamless user experience.

EDUCATION & CERTIFICATIONS

[IBM Cognitive Class – Python for Data Science \(2025\)](#)

Machine Learning, Data Science and Generative AI with Python – Udemy  Ongoing

[SQL Basic- HackerRank](#)

[AWS \(Hands-on Lab Experience | AWS Identity and Access Management \(IAM\) | AWS Cloud Quest: Generative AI](#)

SKILLS

Languages: Java, Python, TypeScript, SQL

Backend: Spring Boot, Spring Data JPA, Spring Security, Hibernate, FastAPI, RESTful API

Frontend: Vue.js 3, TypeScript, HTML5, CSS3, Axios

AI / NLP: Hugging Face Transformers, SpaCy, Sentiment Analysis

Database: PostgreSQL, MySQL, Firebase

Development Tools: GitHub, Postman, DBeaver, Docker, IntelliJ IDEA, VS Code

LANGUAGE

English- B2



CONTACT

05417277685

cansuy614@gmail.com

Istanbul, Turkey

<https://www.linkedin.com/in/cansuyildirim/>

<https://github.com/cansuyildirim>

<https://medium.com/@cansuy614>

EDUCATION

2022 - 2026

ISTANBUL HEALTH AND
TECHNOLOGY UNIVERSITY

- B.Sc. in Computer Engineering
(Full Scholarship)
- GPA: 3.52 / 4.0

2016 - 2020

BURSA ERKEK LİSESİ

- High School
- Ranked 4th among graduates

TECHNICAL SKILLS

- Programming: Python, Java, C, C#, SQL
- AI & ML: Machine Learning, Deep Learning, Prompt Engineering, RAG-based Chatbots
- Data Engineering: ETL Pipelines, Apache Airflow, dbt, PostgreSQL
- Automation: n8n, Webhook-based Systems, API Integrations

AYŞE CANSU YILDIRIM

COMPUTER ENGINEERING STUDENT

EXPERIENCE

AI & Automation Engineering Intern (Remote)

izyGrow | Nov 2025 - Jan 2026

- Developed workflow automations using n8n, Replicate, Hugging Face and various AI models
- Built API-based integrations with Telegram, Google Sheets and other external systems
- Actively participated in AI-driven product development processes (PoC → MVP)
- Conducted cost analysis, model benchmarking and technical research, gaining hands-on experience in transforming ideas into production-ready solutions

Data Engineering Intern

Digiturk - beIN MEDIA Group | Jul 2025 - Aug 2025

- Developed customer churn prediction models using Python and machine learning algorithms
- Contributed to customer churn analysis projects through data-driven modeling and evaluation
- Designed automated data transformation pipelines using Docker Compose, PostgreSQL, dbt and Apache Airflow
- Built datamarts and developed dashboards aligned with the company's data strategy and analytics standards

AI R&D Intern

BRM Software | Jul 2024 - Aug 2024

- Gained hands-on experience in Python, Machine Learning, Computer Vision, Prompt Engineering and chatbot development
- Adapted quickly to the professional work environment through project presentations, team collaboration, and regular meetings
- Developed and delivered three AI-focused projects during the internship:
- Emotion Analysis System: Built a real-time emotion recognition system using camera-based computer vision techniques
- BRM Website Chatbot: Developed a chatbot that answers user inquiries based on BRM Software's website content
- BRM AI-Powered Support System: Designed an AI-driven customer support solution to assist service operations

Software Development Intern

BRM Software | Aug 2023 - Sep 2023

- Volunteered as a Software Development Intern at the end of my first academic year, significantly strengthening my software development skills
- Enhanced communication, teamwork and problem-solving abilities through collaborative project work
- Developed a restaurant automation system using C# and Microsoft SQL Server

VOLUNTEER & LEADERSHIP EXPERIENCE

AI & Technology Academy - Scholar | Dec 2024 - Aug 2025

- Trained in generative AI models and AI-powered application development
- Gained foundational experience in frontend and backend web development
- Participated in hackathons and ideathons with cross-functional teams

- DevOps: Docker, Docker Compose
- Data Science: NumPy, Pandas, Scikit-learn, Feature Engineering
- Mobile & Other: Flutter, OOP, Data Structures & Algorithms

SOFT SKILLS

- Strong communication and stakeholder collaboration
- Team-oriented mindset with leadership experience
- Problem-solving and analytical thinking
- Ownership mentality and responsibility-driven work approach
- Adaptability and fast learning in dynamic environments
- Presentation, mentoring, and knowledge-sharing skills

LANGUAGES

- Turkish: Native
- English: Professional Working Proficiency

INTERESTS

- Literature and poetry writing
- Photography
- Turkish Classical Music choir participation
- Hiking and nature walks
- Interest in psychological research

IEEE ISTUN Computer Society – Mentor | Nov 2024 – Present

- Mentored student teams developing Flutter-based mobile applications
- Contributed to the project lifecycle from planning to delivery
- Participated as an active developer in a TÜBİTAK 2209-A supported project

YetGen – Education Leader (MZV-MEF YetGen'2024-1) | Feb 2024 – May 2024

- Supported a cohort of 26 participants throughout the full program lifecycle
- Organized weekly meetings, progress tracking and assignment reviews
- Delivered workshops on CV preparation and LinkedIn usage
- Evaluated project ideas and presentations, providing constructive feedback

YetGen – Digital Marketing Team Lead | March 2024 – February 2025

- Planned and coordinated digital content production for program communications
- Analyzed engagement metrics and content performance

Google Developer Student Clubs Turkey – Head of Business Development / Core Team Member | Oct 2023 – Aug 2024

- Led business development initiatives and contributed to strategic planning

Mirketgiller – Head of Sponsorship | Oct 2023 – Jun 2024

- Managed sponsorship relations and partnerships

YetGen – Education Leader (Zorlu-MEF Teacher Training Program) | Oct 2023 – Aug 2024

- Served as an education leader in a 7-week teacher training program
- Facilitated workshops and provided project evaluations and feedback

YetGen – Participant (MZV-MEF YetGen'2023-1) | Apr 2023 – Jul 2023

- Completed a 9-week multidisciplinary development program
- Strengthened skills in leadership, teamwork, communication and problem-solving

CERTIFICATIONS

- AI and Technology Academy Graduation Certificate
- Google Project Management Professional Certificate (Coursera) – Specialization including: Foundations of Project Management, Project Initiation, Project Planning, Project Execution, Agile Project Management and Capstone Project.
- AI and Technology Academy Hackathon Participation Certificate – Google
- YetGen'2024-1 Leadership Certificate – YetGen
- YetGen 2023-2024 Teacher Training Leadership Certificate – YetGen
- YetGen'2023-1 Participant Certificate – YetGen
- 2023-2024 GDSC Core Member Certificate – Google Developer Student Clubs Turkey
- Akbank Deep Learning Bootcamp Participation Certificate – Akbank & Global AI Hub
- CyberStart (IBM & Kodluyoruz) – IBM
- ChatGPT Masterclass: Beginner to Advanced Prompt Engineering – Yapaylar
- Data Science and Machine Learning 2026: 100-Day Camp – Atıl Samancıoğlu

PROJECTS

- AI-Powered Mobile Education App for Disabled Primary School Students - TÜBİTAK 2209-A Supported Project
- AI-Supported Department Employee Performance Analysis System - Graduation Project
- Virtual Boutique Automation System
- BRM AI-Powered Support System & BRM Website Chatbot
- Automated Customer Analytics Pipeline
- Digiturk Internship Project
- CustomerIQ – End-to-End E-Commerce Customer Analytics Platform

PROJE GİTHUB LİNKİ : <https://github.com/ddemi-ssena/PROPEL-AI-Performance>

İNTİHAL TEST:

[illegible]

